

Analyse epi Daten, originär vs aus klin. generiert

Table of contents

- Analyse epi Daten, originär vs aus klin. generiert
 - Zusammenfassung
 - intro code
 - load data
 - Analyse
 - epi Daten aus klin ("neu")
 - epi Daten originär ("alt")
 - Beispiel aus *neuen epi Daten*: Person mit max. Anzahl Tumormeldungen
 - Datenstand

Zusammenfassung

- Hintergrund
 - Bei den epi Daten wird ein Algorithmus eingesetzt zur Erkennung von Mehrfachtumoren
 - Tumore, die nach dieser Erkennung als "nicht-mehrfach" markiert werden, bekommen eine aufsteigende Zählnummer (**TUMID**)
 - die TUMID gibt also an, wie viele Tumore einer Person jeweils zugeordnet sind, in welcher Reihenfolge
 - Tumore mit leerer TUMID werden als Mehrfachtumore ausgeschlossen
- Ziel
 - der Algorithmus soll auf die aus den klinischen Daten abgeleiteten epi Daten angewandt werden, insbesondere auf die Daten der Neuen Bundesländer (NBL)
 - zu prüfen: entstehen dabei Artefakte in den Daten?
- Daten (beides inklusive aller auszuschliessenden Fälle auf Basis von A Prüfungen)
 - originäre epi Daten (alt)
 - aus klin Daten abgeleitete epi Daten (neu)
- Fazit: **die Identifikation von Mehrfachtumoren (=Zuordnung von leerer TUMID) führt in den neuen Daten zu vergleichbaren Effekten wie in den alten Daten und erscheint somit geeignet. Ein Ausschluss der sehr ähnlichen best-of Meldungen sollte dennoch vorab geprüft werden. Aktuell würden ~6.9k Fälle als Mehrfachtumore ausgeschlossen werden**

load data

pandas: 2.2.2 | numpy: 1.26.4 | duckdb: 1.0.0 | pandas-plots: 0.11.2 | connection_helper: 0.7.2

kkrr	05-NW	09-BY	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
HISC									
9617	0	2	0	1	1	2	1	1	8
9697	46	0	0	0	1	2	1	0	50
9990	0	0	955	1_245	33	5	4	57	2_299
Total	46	2	955	1_246	35	9	6	58	2_357

Analyse

- Anteil an leeren TUMID (=Mehrfachtumor) in beiden Datenräumen konstant bei 0.3% In der Verteilung nach KR gibt es keine Häufungen
- in neuen epi Daten: max 54 Fälle einem Patienten zugeordnet (alten Daten: 8) was an nicht aufgelösten best-of Meldungen liegen kann
- die Verteilung der TUMID ist in beiden Datensätzen ähnlich (abgesehen von den seltenen Extremwerten in den neuen Daten)
- neue Daten: in den NBL liegt die durchschn. TUMID leicht höher als im Westen, was tendenziell mehr zu der hohen Zahl an best-of Meldungen beiträgt

TUMID=0 kann offenbar im Algorithmus gesetzt werden (wenn Fall in Menge A3), und wird in der Union SQL Tabelle auf Ebene 4 geschrieben. Diese (wenigen) Fälle werden auf Ebene 5 dann zu TUMID=1, da die Reihenfolge der TUMID dann ausgezählt wird. RKI Doku hier
A3: Hilfsmenge: alle Meldungen, die eine ungültige Kombination von ICD10/DIG/HISC aufweisen (müsste nach der Neukodierung eigentlich ausgeschlossen sein). Diese Menge wird von der Grundmenge A1 abgezogen, es verbleiben nur gültige Meldungen

epi Daten aus klin ("neu")


Fallzahl: 2_307_232 | leere TUMID: 6_928 | Quota = 0.30%
max. TUMID im Datensatz: 54
Verteilung #TUMID pro EKR (mean):

EKRNR	01	02	03	04	05	06	07	08	09	10	11	12	13	14	15	16
TUMID	1.086	1.070	0.996	1.089	1.054	1.032	0.956	1.034	1.226	1.041	1.010	1.133	1.430	2.022	1.520	2.052


Verteilung leere TUMID pro EKR (Anteil in %):

EKRNR	01	02	03	04	05	06	07	08	09	10	11	12	13	14	15	16
Gesamt	106_085	53_582	148_351	19_202	541_490	112_553	87_374	244_671	318_061	32_814	81_867	76_839	78_599	249_258	93_698	62_788
TUMID_empty	140	139	87	5	2_162	55	68	2_208	705	39	194	383	135	323	188	97
pct	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

TOP 20 [count] by [TUMID_], n=2_307_232



[EKRNR] by TOP10 [TUMID_], n=2_307_232



epi Daten originär ("alt")


Fallzahl: 12_009_425 | leere TUMID: 45_418 | Quota = 0.38%
max. TUMID im Datensatz: 10
Verteilung #TUMID pro EKR (mean):

EKRNR	01	02	03	04	05	06	07	08	09	10
TUMID	1.205	1.183	1.195	1.199	1.154	1.116	1.161	1.126	1.128	1.156


Verteilung leere TUMID pro EKR (Anteil in %):

EKRNR	01	02	03	04	05	06	07	08	09	10
Gesamt	734_305	423_109	1_816_413	151_753	3_881_747	918_534	823_343	1_048_203	1_811_372	400_646
TUMID_empty	1_333	3_155	16_164	336	9_038	1_510	2_490	1_169	2_139	8_084
pct	0	0	0	0	0	0	0	0	0	2

TOP 20 [count] by [TUMID_], n=12_009_425



[EKNR] by TOP10 [TUMID_], n=12_009_425



Beispiel aus neuen epi Daten: Person mit max. Anzahl Tumormeldungen

- derzeit: max 54 (mit TUMID gezählte) Fälle zu einer Person, davon hier 10 gezeigt

	EKNR	TUMID	DALTIMP	ICDGM10DREI	ICDO3	DSICH	DIG	HISC	DCO	DJ	LOKGRP	HISCGRP
1648505	14	1	68.0	C44	C4453	7	3	8091	2	2010.0	C44	2
1801754	14	2	68.0	C44	C4431	7	3	8092	2	2010.0	C44	2
2023551	14	3	68.0	C44	C4432	7	3	8090	2	2010.0	C44	2
2085456	14	4	68.0	C44	C4452	7	3	8091	2	2010.0	C44	2
260086	14	5	68.0	C44	C4461	7	3	8091	2	2010.0	C44	2
1876139	14	6	69.0	C44	C4451	7	3	8091	2	2011.0	C44	2
1358970	14	7	69.0	C44	C4453	7	3	8091	2	2011.0	C44	2
2215455	14	8	69.0	C44	C4451	7	3	8090	2	2011.0	C44	2
534684	14	9	69.0	C44	C4453	7	3	8091	2	2011.0	C44	2
1964870	14	10	70.0	C44	C4461	7	3	8091	2	2012.0	C44	2

Datenstand

new data to sql: 2024-06-07 13:38:35
old data to sql: 2024-06-18 14:44:34
notebook as of : 2024-06-23 21:11:09