

Technische Prüfungen in klinischen und epi Daten

Table of contents

- Technische Prüfungen in klinischen und epi Daten
 - Zusammenfassung 
 - load data 
 - Datenstand 
 - Qualitätsprüfungen
 - geschlecht_missing
 - verstorben_missing
 - diagnose_missing
 - Beispielabfrage in epi Daten: woher stammen die Leerkodierungen in 06-HE?
 - inzidenzort_missing
 - geschlecht_icd_konflikt
 - datum_missing
 - datum_fehlerhaft
 -  duplikat_id
 - duplikat_verdacht
 - Verteilung nach Inzidenzort
 - Verteilung nach Diagnosejahr
 - Verteilung nach ICD10
 - Verteilung der Gruppen mit gleichen Merkmalen

Zusammenfassung

- Ziel der Auswertungen ist es, Qualitätsprüfungen auf **technischer** Ebene darzustellen
- im Abgrenzung zu den **inhaltlichen** Prüfungen des klinischen Datenberichtes sollen hier eher Auffälligkeiten des Verarbeitungsprozesses sichtbar werden, z.B. missings / Konflikte bei zentralen Variablen wie Datumsangaben, Geschlecht etc.
- die Auswertungen sind angelehnt an die bei den epi Daten etablierten *ABC Prüfungen* (siehe [Bericht zur Datenqualität \(epi2023\)](#))
- die Abgrenzung dieses Dokumentes zum DQ Bericht epi ist derzeit nicht zufriedenstellend gelöst und muss zukünftig verbessert werden
- dargestellt sind hier jeweils Auffälligkeiten sowohl in den klinischen als auch in den epi Daten
- eine Besonderheit stellt die Prüfung auf **Duplikatverdacht** dar. Wir haben festgestellt, dass bei einer nicht unerheblichen Zahl von Fällen gleiche Ausprägungen bei einem set von Merkmalen vorliegt. Nach dem letzten update ist dieser Anteil jedoch erheblich kleiner geworden
- weiterhin nehmen wir bei keinem dieser Prüfungen eine Korrektur in den klinischen Daten vor

load data

 3.12.2 |  pandas: 2.2.3 |  numpy: 1.26.4 |  duckdb: 1.1.2 |  pandas-plots: 0.11.15 |  connection_helper: 0.8.10

Datenstand

- **!** die epi Daten der ehemaligen GKR Länder sind seit dem letzten Bericht **nicht** aktualisiert **!**
sqlite db file: 2024-10-22_data_clin.db last kkr data import: 2024-09-20 sql table created: 2024-10-22 08:59:29 sql table transmitted: 2024-10-22 10:25:35 document created: 2024-10-22 17:57:07
sqlite db file: 2024-08-01_data_epi.db data tag: epi2023_1b sql table created: 2024-08-01 10:06:58 sql table transmitted: 2024-08-16 17:14:58 document created: 2024-10-22 17:57:07

Qualitätsprüfungen

- kein Filter, die Prüfungen wirken auf den gesamten Datenbestand
- zur Darstellung wird eine heatmap verwendet, dem maximalen Wert je Prüfung wird die kräftigste Farbe zugewiesen. Aus diesem relativ gesetzten Farbton ist nicht ableitbar, wie schwerwiegend die Fallzahl ist

geschlecht_missing

- Variable Geschlecht / SEX missing

  klin

	kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_missing		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

  epi

	kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_missing		0	47	3	16	0	1_657	136	372	125	0	28	6	9	5	3	6	2_413

verstorben_missing

- Variable Verstorben / TOD missing

 TOD wird in den epi Daten imputiert, kann also dort auch nicht fehlen

  klin

	kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
verstorben_missing		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

  epi

	kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
verstorben_missing		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

diagnose_missing

- Variable Diagnose_ICD10_Code ist

- leer (konkret sind hier die Felder bei der Übermittlung zumeist nicht fehlend, sondern als ' ' kodiert)
- oder nicht in [C,D]

 klin: nur wenige Kodierungen im Datensatz aus anderen Kapiteln

 epi: In den ABC Prüfungen der epi Daten wird getestet, ob ein Diagnosecode leer ist oder ausserhalb des "Diagnosebandes" des ZfKD (konkret: A_ICD10_keineAuswertung[54]). Der Test ist auch im Datenbericht der epi Daten sichtbar, dort wird allerdings nur das letzte DJ herangezogen, um auf die aktuelle Entwicklung zu fokussieren.

  klin

	kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
diagnose_missing		0	0	0	0	0	0	0	0	63	0	5	293	291	0	0	47	699

Verteilung icd10 ausserhalb [C,D]: {' ': 682, 'I88': 1, 'K20': 1, 'K50': 1, 'K51': 1, 'K63': 12, 'N30': 1}

  epi

	kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
diagnose_missing		10	6	2_323	283	10_810	1_214	1_641	4_265	2_477	2_322	2_919	2_704	437	335	1_664	536	33_946

Verteilung icd10 ausserhalb [C,D]: {None: 34126}

Beispielabfrage in epi Daten: woher stammen die Leerkodierungen in 06-HE?

- Top 10 Kombinationen ICD10, Dignität (beide Originalwerte bei Lieferung) und (neukodierte) ICD10 ist leer

 in den meisten Fällen liegt bei Lieferung ein ICD10 Code innerhalb des ZfKD Diagnosebandes vor. Die Neukodierung im epi workflow vergibt bei unpassenden Dignitäten keine neue Diagnose, und die Fälle werden somit im Ergebnis zu missing

EKRNR varchar	ICDGM10_02 varchar	DIG_03 int64	cnt int64
06	D35.2	0	950
06	D35.2	-999	34
06	C61	9	5

06	C56	9	5
06	C44.3	9	4
06	C34.9	9	3
06	C44.6	9	3
06	C85.1	3	3
06	D75.8	-999	3
06	C44.5	9	3
10 rows		4 columns	

inzidenzort_missing

- Variable **Inzidenzort** fehlt, oder ist unbrauchbar kodiert (00000, 99999, oder Länge != 5)

epi: die Variable GKZlk wird nachbearbeitet im workflow

klin

kkcr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
ort_missing	0	0	0	0	0	0	0	0	27	0	0	0	724	0	1	1	753

Verteilung inzidenzort missing oder ungültig{'': 686, '0': 10, '00000': 1, '05': 2, '13': 32, '9': 10, '99999': 12}

epi

kkcr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
ort_missing	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

Verteilung inzidenzort missing oder ungültig{}

geschlecht_icd_konflikt

- Widerspruch zwischen Geschlecht und ICD10, eines der Kombinationen:
 - männlich und ['C51', 'C52', 'C53', 'C54', 'C55', 'C56', 'C57', 'C58']
 - weiblich und ['C60', 'C61', 'C62', 'C63']

klin

kkcr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_icd_konflikt	0	0	2	0	4	0	1	1	2	2	2	0	2	0	1	1	18

Kombination Geschlecht / ICD10 ungültig: {'C61-W': 11, 'C51-M': 2, 'C56-M': 2, 'C53-M': 1, 'C58-M': 1, 'C54-M': 1}

epi

kkcr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_icd_konflikt	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

Kombination Geschlecht / ICD10 ungültig: {}

datum_missing

- Diagnosedatum** oder **Geburtsdatum** ist leer (bzw. als Jahr 1900 kodiert)
- nicht gesetzte Angaben zum Vitalstatus sind ignoriert

hier sind auch regulär übermittelte Fälle mit vollständig (V) geschätztem Datum enthalten

klin

kkcr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_missing	7	13	2	26	1_046	116	8	653	598	1	103	24	30	128	475	50	3_280

Verteilung top 3 (GebDat - DiagDat): {'<NA>-2020-01-15': 39, '<NA>-2020-07-15': 38, '<NA>-2021-11-15': 38}

epi

kkcr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_missing	55	336	90	7	585	246	52	0	14	2_120	447	540	318	282	5_223	629	10_944

Verteilung top 3 (GebDat - DiagDat): {'<NA>-': 189, '1945-01-15-1900-04-15': 35, '1938-09-15-1900-04-15': 34}

datum_fehlerhaft

- Vitalstatus vor Geburt oder Diagnose vor/gleich Geburt
 - alle 3 beteiligten Felder dürfen nicht missing sein
- klin

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_fehlerhaft	5	0	0	0	4	5	0	20	15	1	0	0	3	3	0	0	56	

Verteilung datum_fehlerhaft top 5:

Geburtsdatum date	Diagnosedatum date	cnt int64
2022-09-15	2022-09-15	4
2020-12-15	2020-12-15	3
2020-11-15	2020-11-15	3
2020-01-15	2020-01-15	3
2020-10-15	2020-10-15	3

epi

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_fehlerhaft		20	15	102	4	229	145	52	106	73	22	79	64	29	81	56	43	1_120

Verteilung datum_fehlerhaft top 5:

Geburtsdatum date	Diagnosedatum date	cnt int64
2013-09-15	2013-09-15	12
2019-04-15	2019-04-15	10
2019-03-15	2019-03-15	10
2013-11-15	2013-11-15	10
2013-04-15	2013-04-15	10

NEW

duplikat_id

- analysiert werden Tumorfälle auf Basis gleicher Tumor_ID (original gelieferte Id)
- ebenfalls herangezogen wird ein # hash-wert über eine Auswahl von Spalten
- haben Tumorfälle den gleichen hash-wert, kann eine inhaltliche Gleichheit angenommen werden

- 🔔 Echte Duplikate stellen Fälle mit gleicher Id und gleichem hash-wert dar. Davon gibt es allerdings nur eine geringe Menge, darunter ein Duplikat innerhalb der gleichen Lieferdatei. Keine Gefahr für die Verarbeitung
- 🔔 Duplikate mit gleicher Id ohne inhaltliche Gleichheit sind häufiger, stellen aber lediglich eine Folge der Id Vergabe im GTDS Verbund dar. Da in der Verarbeitung eine zufällige uuid vergeben wird entstehen hier auch keine Kollisionen

Für den hash-wert sind folgende Spalten herangezogen:
Diagnose_ICD10_Code, Morphologie_Code, Topographie_Code, Geburtsdatum, Diagnosedatum, Geschlecht, Verstorben, Inzidenzort, Seitenlokalisation, T_p, Grading, N_p, Diagnosesicherung, M_p

Echte Duplikate (gleiche Tumor_ID UND gleicher Inhalt/hash):

Tumor_ID varchar	kk_r varchar	same_kkr boolean	same_file boolean	cnt int64
0000009174_2	09	true	true	2
0000000005_1	11	true	false	2
0000000005_3	11	true	false	2
0000000030_1	11	true	false	2
0000000030_2	11	true	false	2
0000001377_3	12	true	false	2
0000000388_2	12	true	false	2
0000000388_1	12	true	false	2
0000001377_2	12	true	false	2
0000000380_2	12	true	false	2
0000001377_1	12	true	false	2
0000000380_1	12	true	false	2
0000000380_3	12	true	false	2
13 rows				5 columns

Duplikate (gleiche Tumor_ID):

Lieferregister varchar	cnt int64
09	89116
11	30215
12	28542
13	72522
15	83772

duplikat_verdacht

- Tumor_ID werden hier ignoriert
- es wird für alle Tumorfälle geprüft, ob es Fälle mit gleicher Kombination verschiedener Merkmale gibt
- Verdachtsfälle mit gleicher Kombination aus verschiedenen Registern und Patienten sind möglich
- die Übereinstimmungswahrscheinlichkeit steigt deutlich, wenn mehr Merkmale leer sind

nach dem letzten Datenuptdate aus SN sind die Duplikatverdacht Fälle hier deutlich zurückgegangen

Verwendete Merkmale: Diagnose_ICD10_Code, Morphologie_Code, Topographie_Code, Geburtsdatum, Diagnosedatum, Geschlecht, Verstorben, Inzidenzort, Seitenlokalisation, T_p, Grading, N_p, Diagnosesicherung, M_p

klin

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
duplikat_verdacht		44	612	333	26	469	168	123	364	2_022	30	3_794	2_794	233	267	228	463	11_970

epi


	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
duplikat_verdacht		414	2_010	7_444	156	4_591	1_087	2_384	799	1_782	488	3_999	733	437	1_599	929	737	29_589

Verteilung nach Inzidenzort

- im Amtlichen Gemeindeschlüssel existieren 2 codes für Leipzig, (Stand 2008, 2014)


klin

TOP 20 [cnt] by [label], n=11_970



epi


TOP 20 [cnt] by [label], n=29_627



Verteilung nach Diagnosejahr


klin

TOP 20 [cnt] by [DJ], n=11_970



epi


TOP 20 [cnt] by [DJ], n=29_627



Verteilung nach ICD10


klin

TOP 10 [cnt] by [icd10_3d], n=11_970



 epi

TOP 10 [cnt] by [icd10_3d], n=29_627



Verteilung der Gruppen mit gleichen Merkmalen

- "Gruppe" = >1 Verdachtsfälle mit gleichen Merkmalen
- verwendete Metriken (jeweils aufgetragen: `is_equal` = "alle Fälle in der Gruppe haben den gleichen Wert")

es gibt wenige Gruppen, in denen die Duplikate aus verschiedenen kkr stammen
in den meisten Gruppen stammen die Duplikate nicht von einem einzelnen Patienten

 klin
11_970 Fälle verteilen sich auf 5_915 Gruppen mit max 5 Fällen in einer Gruppe
Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: REGISTER {True: 5772, False: 143}
Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: PATIENTID {False: 5260, True: 655}

 epi
29_627 Fälle verteilen sich auf 14_660 Gruppen mit max 8 Fällen in einer Gruppe
Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: REGISTER {True: 14660}
Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: PATIENTID {False: 13684, True: 976}