

Technische Prüfungen in klinischen und epi Daten

Table of contents

- Technische Prüfungen in klinischen und epi Daten
 - Hintergrund
 - Zusammenfassung 
 - load data 
 - Datenstand 
 - Qualitätsprüfungen
 - geschlecht_missing
 - verstorben_missing
 - diagnose_missing
 - inzidenzort_missing
 - geschlecht_icd_konflikt
 - datum_missing
 - datum_fehlerhaft
 - Duplikate
 - Echte Duplikate
 - Duplikatverdacht
 - Verteilung nach Inzidenzort
 - Verteilung nach Diagnosejahr
 - Verteilung nach ICD10
 - Verteilung der Gruppen mit gleichen Merkmalen

Hintergrund

- Ziel der Auswertungen ist es, Qualitätsprüfungen auf **technischer** Ebene darzustellen
- im Abgrenzung zu den **inhaltlichen** Prüfungen des klinischen Datenberichtes sollen hier eher Auffälligkeiten des Verarbeitungsprozesses sichtbar werden, z.B. missings / Konflikte bei zentralen Variablen wie Datumsangaben, Geschlecht etc.
- die Auswertungen sind angelehnt an die bei den epi Daten etablierten *ABC Prüfungen* (siehe [Bericht zur Datenqualität \(epi2023\)](#))
- die Abgrenzung dieses Dokumentes zum DQ Bericht epi ist derzeit nicht zufriedenstellend gelöst und muss zukünftig verbessert werden
- dargestellt sind hier jeweils Auffälligkeiten sowohl in den klinischen als auch in den epi Daten
- weiterhin nehmen wir bei keinem dieser Prüfungen eine Korrektur in den **klinischen Daten** vor

Zusammenfassung

- **fehlendes Geschlecht** tritt nicht auf in den klinischen Daten, in den epi Daten überwiegend in **06-HE**
- für **fehlende Diagnose** bei den klinischen Daten gibt es einige wenige Fälle in **13-MV** und **16-TH**. Für die epi Daten ist eine Bewertung schwierig aufgrund der vielfältigen Bearbeitungsschritte nach Lieferung
- fehlender Inzidenzort tritt in den klinischen Daten nur in **13-MV** auf. Bei den epi Daten wird diese Variable bei missings auto-korrigiert
- Widerspruch zwischen Geschlecht und Diagnose ist in den klinischen Daten eine Randerscheinung, in den epi Daten treten diese Kombinationen inzwischen nicht mehr auf
- fehlende Datumsangaben sind in den klinischen Daten in etwa proportional zur Registergrösse, bei den epi Daten überwiegend in **10-SL**
- **echte Duplikate** (gleiches set an Merkmalen und gleiche ID) für klinische Daten kommen ausschliesslich aus **09-BY**, bleiben aber Randfälle
- **Duplikatverdachtsfälle** sind deutlich weniger auffällig als letztes Jahr. Diese verteilen sich hauptsächlich auf **11-BE**, **09-BY** und **03-NI**, was möglicherweise an lokalen Häufungen von Fällen mit gleichem Inzidenzort liegt

load data

 3.13.2 |  pandas: 2.3.0 |  numpy: 1.26.4 |  duckdb: 1.3.1 |  pandas-plots: 0.12.27 |  connection-helper: 0.11.1

Datenstand

```
sqlite db file:      2025-06-24_data_clin.duckdb
data tag:            v2.2
last kkr data import: 2025-05-27
sql table created:   2025-06-24 13:47:18
sql table transmitted: 2025-06-25 08:33:57
document created:    2025-06-27 11:32:37

sqlite db file:      2025-06-20_data_epi.duckdb
data tag:            epi2024_2
sql table created:   2025-06-20 15:31:26
sql table transmitted: 2025-06-23 08:57:10
document created:    2025-06-27 11:32:37
```

Qualitätsprüfungen

- kein Filter, die Prüfungen wirken auf den gesamten Datenbestand
- zur Darstellung wird eine heatmap verwendet, dem maximalen Wert je Prüfung wird die kräftigste Farbe zugewiesen. Aus diesem relativ gesetzten Farbton ist nicht ableitbar, wie schwerwiegend die Fallzahl ist

geschlecht_missing

- Variable Geschlecht / SEX missing

 klin

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_missing		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

 epi

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_missing		0	47	0	18	0	1_559	0	357	106	0	31	6	18	5	5	17	2_169

verstorben_missing

- Variable Verstorben / TOD missing

 Die Variable TOD wird in den epi Daten imputiert, kann also dort auch nicht fehlen

 klin

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
verstorben_missing		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

 epi

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
verstorben_missing		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

diagnose_missing

- Variable Diagnose_ICD10_Code ist
 - leer (konkret sind hier die Felder bei der Übermittlung zumeist nicht fehlend, sondern als '' kodiert)
 - oder nicht in [C,D]

 klin: nur wenige Kodierungen im Datensatz aus anderen Kapiteln

 epi: In den ABC Prüfungen der epi Daten wird getestet, ob ein Diagnosecode leer ist oder ausserhalb des "Diagnosebandes" des ZfKD (konkret: A_ICD10_keineAuswertung[54]). Der Test ist auch im Datenbericht der epi Daten sichtbar, dort wird allerdings nur das letzte DJ herangezogen, um auf die aktuelle Entwicklung zu fokussieren.

 klin

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
diagnose_missing		0	0	0	0	0	0	0	0	0	0	0	4	393	0	0	148	545

Verteilung icd10 ausserhalb [C,D]: {None: 545}

 epi

	kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
diagnose_missing		12	9	2_530	302	11_416	169	296	4_707	2_979	193	4_120	3_686	364	464	2_455	746	34_448

Verteilung icd10 ausserhalb [C,D]: {None: 34482}

inzidenzort_missing

- Variable Inzidenzort fehlt, oder ist unbrauchbar kodiert (00000, 99999, oder Länge != 5)

 epi: die Variable GKZlk wird nachbearbeitet im workflow

 klin

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
ort_missing	0	0	0	0	0	1	0	0	4	0	0	36	1_008	0	0	0	1_049

Verteilung inzidenzort missing oder ungültig{'99999': 49, None: 1000}

epi

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
ort_missing	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

Verteilung inzidenzort missing oder ungültig{}

geschlecht_icd_konflikt

- Widerspruch zwischen Geschlecht und Diagnose, eines der Kombinationen:
 - männlich und ['C51', 'C52', 'C53', 'C54', 'C55', 'C56', 'C57', 'C58']
 - weiblich und ['C60', 'C61', 'C62', 'C63']
- klin

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_icd_konflikt	1	0	3	0	7	0	5	5	7	1	6	3	0	0	1	1	40

Kombination Geschlecht - ICD10 ungültig: {'C61-W': 24, 'C54-M': 4, 'C51-M': 2, 'C62-W': 2, 'C56-M': 2, 'C58-M': 1, 'C57-M': 1, 'C52-M': 1, 'C63-W': 1, 'C53-M': 1, 'C55-M': 1}

epi

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_icd_konflikt	1	0	0	0	0	0	0	0	0	1	5	3	0	0	1	0	11

Kombination Geschlecht - ICD10 ungültig: {'C61-W': 7, 'C62-W': 1, 'C52-M': 1, 'C63-W': 1, 'C56-M': 1}

datum_missing

- Diagnosedatum oder Geburtsdatum ist leer (bzw. als Jahr 1900 kodiert)
 - nicht gesetzte Angaben zum Vitalstatus sind ignoriert
- ⚠ hier sind auch regulär übermittelte Fälle mit vollständig (V) geschätztem Datum enthalten

klin

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_missing	17	36	78	21	1_353	279	51	1_019	1_112	2	555	127	50	178	640	65	5_583

Verteilung top 3 (GebDat - DiagDat): {'1900-04-01-2023-07-15': 171, '1900-04-01-2023-01-15': 169, '1900-04-01-2023-06-15': 89}

epi

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_missing	54	313	69	7	585	231	52	0	14	2_120	426	542	168	390	693	329	5_993

Verteilung top 3 (GebDat - DiagDat): {'<NA>': 155, '1932-06-15-1900-04-15': 12, '1939-10-15-1900-04-15': 12}

datum_fehlerhaft

- Vitalstatus vor Geburt oder Diagnose vor/gleich Geburt
 - alle 3 beteiligten Felder dürfen nicht missing sein
- klin

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_fehlerhaft	5	0	0	0	9	8	0	39	23	3	1	0	2	3	0	0	93

Verteilung datum_fehlerhaft top 5:

Geburtsdatum date	Diagnosedatum date	cnt int64
2023-03-15	2023-03-15	4

2020-10-15	2020-10-15	3
2023-11-15	2023-11-15	3
2021-11-15	2021-11-15	3
2021-01-15	2021-01-15	3

epi

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_fehlerhaft	20	17	104	4	241	148	51	111	74	24	80	61	31	72	48	40	1_126

Verteilung datum_fehlerhaft top 5:

Geburtsdatum date	Diagnosedatum date	cnt int64
2013-09-15	2013-09-15	12
2013-11-15	2013-11-15	10
2013-04-15	2013-04-15	10
2019-03-15	2019-03-15	10
2019-04-15	2019-04-15	10

Duplikate

- Echte Duplikate stellen Fälle mit gleicher Id und gleichem hash-wert dar
- Duplikat-Verdacht: Duplikate mit gleicher Id, aber ohne inhaltliche Gleichheit sind häufiger, stellen aber lediglich eine Folge der Id Vergabe im GTDS Verbund dar. Da in der Verarbeitung eine zufällige uuid vergeben wird entstehen hier auch keine Kollisionen

Echte Duplikate

- analysiert werden Tumorfälle auf Basis gleicher Tumor_ID (original gelieferte Id)
- ebenfalls herangezogen wird ein # hash-wert über eine Auswahl von Spalten
- haben Tumorfälle den gleichen hash-wert, kann eine inhaltliche Gleichheit angenommen werden
- Ergebnis
 - ~1000 Paare mit echten Duplikaten sind in den Daten, alle aus 09-BY.
 - keine der Paare sind innerhalb einer Lieferdatei, also keine Gefahr für die Verarbeitung
 - im Beispiel sind zwei Tumore mit gleicher originalen ID und gleichem hash-wert, aber verschiedenen Dateien
 - in allen Duplikaten werden technische ID neu vergeben, es kommt also nicht zu Kollisionen

Tests:

Für den hash-wert sind folgende Spalten herangezogen:
Diagnose_ICD10_Code, Morphologie_Code, Topographie_Code, Geburtsdatum, Diagnosedatum, Geschlecht, Verstorben, Inzidenzort, Seitenlokalisation, T_p, Grading, N_p, Diagnosesicherung, M_p

Echte Duplikate (gleiche Tumor_ID UND gleicher Inhalt/hash):

kkp int32	same_kkp boolean	same_file boolean	cnt_cases int64	max_cases_in_dupl int64	example_Tumor_ID varchar
9	true	false	1096	2	00045650C5B00E9E723E8655919ABBC20F15348B_1

	oBDS_RKIPatientTumorId	Tumor_ID	z_kkp	FileName	hash_cols
0	5600d258-049d-4c77-aa32-34423e7bef8	00045650C5B00E9E723E8655919ABBC20F15348B_1	9	.\09\gtldsexpo_bayreuth_20250109_1\einzeldateie...	0x5A2FC843FF6CC7D80C99AE8DCBBACAD69C1E5989069A...
1	de98bcd4-52df-40ad-b45f-89b1d9b9cb9a	00045650C5B00E9E723E8655919ABBC20F15348B_1	9	.\09\gtldsexpo_erlangen_20250110_1\einzeldateie...	0x5A2FC843FF6CC7D80C99AE8DCBBACAD69C1E5989069A...

Duplikatverdacht

- die originale Tumor_ID wird hier ignoriert
 - es wird für alle Tumorfälle geprüft, ob es Fälle mit gleicher Kombination verschiedener Merkmale gibt
 - Verdachtsfälle mit gleicher Kombination aus verschiedenen Registern und Patienten sind möglich
 - die Übereinstimmungswahrscheinlichkeit steigt deutlich, wenn mehr Merkmale leer sind
- Verwendete Merkmale: Diagnose_ICD10_Code, Morphologie_Code, Topographie_Code, Geburtsdatum, Diagnosedatum, Geschlecht, Verstorben, Inzidenzort, Seitenlokalisation, T_p, Grading, N_p, Diagnosesicherung, M_p

klin

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
duplikat_verdacht	60	664	571	40	1_060	260	158	742	3_106	30	2_118	192	347	370	348	488	10_554

epi


kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
duplikat_verdacht	528	2_100	8_071	197	5_197	1_742	2_670	1_373	2_191	850	5_621	1_031	594	1_885	1_373	1_067	36_490

Verteilung nach Inzidenzort

klin


kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
duplikat_verdacht	528	2_100	8_071	197	5_197	1_742	2_670	1_373	2_191	850	5_621	1_031	594	1_885	1_373	1_067	36_490

TOP 20 [cnt] by [label], n=358 (10_554)



epi


TOP 20 [cnt] by [label], n=408 (36_512)



Verteilung nach Diagnosejahr


klin

TOP 20 [cnt] by [DJ], n=35 (10_554)



epi


TOP 20 [cnt] by [DJ], n=57 (36_512)



klin


Verteilung nach ICD10

TOP 10 [cnt] by [icd10_3d], n=87 (10_554)



epi

TOP 10 [cnt] by [icd10_3d], n=103 (36_512)



Verteilung der Gruppen mit gleichen Merkmalen

- "Gruppe" = >1 Verdachtsfälle mit gleichen Merkmalen
- verwendete Metriken (jeweils aufgetragen: `is_equal` = "alle Fälle in der Gruppe haben den gleichen Wert")

es gibt wenige Gruppen, in denen die Duplikate aus verschiedenen kkr stammen
in den meisten Gruppen stammen die Duplikate nicht von einem einzelnen Patienten

klin

10_554 Fälle verteilen sich auf 5_161 Gruppen mit max 4 Fällen in einer Gruppe
Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: REGISTER {True: 4955, False: 206}
Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: PATIENTID {False: 4525, True: 636}

epi

36_512 Fälle verteilen sich auf 18_022 Gruppen mit max 6 Fällen in einer Gruppe
Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: REGISTER {True: 18022}
Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: PATIENTID {False: 16671, True: 1351}