

# Technische Prüfungen in klinischen und epi Daten

## Table of contents

- Technische Prüfungen in klinischen und epi Daten
  - Hintergrund
  - Zusammenfassung 
  - load data 
  - Datenstand 
  - Qualitätsprüfungen
    - geschlecht\_missing
    - verstorben\_missing
    - diagnose\_missing
    - inzidenzort\_missing
    - geschlecht\_icd\_konflikt
    - datum\_missing
    - datum\_fehlerhaft
  - Duplikate
    - Echte Duplikate
    - Duplikatverdacht
      - Verteilung nach Inzidenzort
      - Verteilung nach Diagnosejahr
      - Verteilung nach ICD10
      - Verteilung der Gruppen mit gleichen Merkmalen

## Hintergrund

- Ziel der Auswertungen ist es, Qualitätsprüfungen auf **technischer** Ebene darzustellen
- im Abgrenzung zu den **inhaltlichen** Prüfungen des klinischen Datenberichtes sollen hier eher Auffälligkeiten des Verarbeitungsprozesses sichtbar werden, z.B. missings / Konflikte bei zentralen Variablen wie Datumsangaben, Geschlecht etc.
- die Auswertungen sind angelehnt an die bei den epi Daten etablierten *ABC Prüfungen* (siehe [Bericht zur Datenqualität \(epi2023\)](#))
- die Abgrenzung dieses Dokumentes zum DQ Bericht epi ist derzeit nicht zufriedenstellend gelöst und muss zukünftig verbessert werden
- dargestellt sind hier jeweils Auffälligkeiten sowohl in den klinischen als auch in den epi Daten
- weiterhin nehmen wir bei keinem dieser Prüfungen eine Korrektur in den **klinischen Daten** vor

## Zusammenfassung

- **fehlendes Geschlecht** tritt nicht auf in den klinischen Daten, in den epi Daten überwiegend in **06-HE**
- für **fehlende Diagnose** bei den klinischen Daten gibt es einige wenige Fälle in **13-MV** und **16-TH**. Für die epi Daten ist eine Bewertung schwierig aufgrund der vielfältigen Bearbeitungsschritte nach Lieferung
- fehlender Inzidenzort tritt in den klinischen Daten nur in **13-MV** auf. Bei den epi Daten wird diese Variable bei missings auto-korrigiert
- Widerspruch zwischen Geschlecht und Diagnose ist in den klinischen Daten eine Randerscheinung, in den epi Daten treten diese Kombinationen inzwischen nicht mehr auf
- fehlende Datumsangaben sind in den klinischen Daten in etwa proportional zur Registergrösse, bei den epi Daten überwiegend in **10-SL**
- **echte Duplikate** (gleiches set an Merkmalen und gleiche ID) für klinische Daten kommen ausschliesslich aus **09-BY**, bleiben aber Randfälle
- **Duplikatverdachtsfälle** sind deutlich weniger auffällig als letztes Jahr. Diese verteilen sich hauptsächlich auf **11-BE**, **09-BY** und **03-NI**, was möglicherweise an lokalen Häufungen von Fällen mit gleichem Inzidenzort liegt

## load data

 3.12.8 |  pandas: 2.3.3 |  numpy: 1.26.4 |  duckdb: 1.4.1 |  pandas-plots: 0.21.3 |  connection-helper: 0.13.1

## Datenstand

```
sqlite db file:      2025-11-11_data_clin.duckdb
data tag:            v2.3
last kkr data import: 2025-09-30
sql table created:   2025-11-11 11:52:01
doi:                 10.18444/5.03.01.0005.0021.0002
document created:    2025-11-17 12:29:01

sqlite db file:      2025-06-20_data_epi.duckdb
data tag:            epi2024_2
sql table created:   2025-06-20 15:31:26
document created:    2025-11-17 12:29:01
```

Qualitätsprüfungen

- kein Filter, die Prüfungen wirken auf den gesamten Datenbestand
- zur Darstellung wird eine heatmap verwendet, dem maximalen Wert je Prüfung wird die kräftigste Farbe zugewiesen. Aus diesem relativ gesetzten Farbton ist nicht ableitbar, wie schwerwiegend die Fallzahl ist

geschlecht\_missing

- Variable Geschlecht / SEX missing

 klin

|                    | kk_r | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|--------------------|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| geschlecht_missing |      | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     |

 epi

|                    | kk_r | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|--------------------|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| geschlecht_missing |      | 0     | 47    | 0     | 18    | 0     | 1_559 | 0     | 357   | 106   | 0     | 31    | 6     | 18    | 5     | 5     | 17    | 2_169 |

verstorben\_missing

- Variable Verstorben / TOD missing

 Die Variable TOD wird in den epi Daten imputiert, kann also dort auch nicht fehlen

 klin

|                    | kk_r | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|--------------------|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| verstorben_missing |      | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     |

 epi

|                    | kk_r | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|--------------------|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| verstorben_missing |      | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     |

diagnose\_missing

- Variable Diagnose\_ICD10\_Code ist
  - leer (konkret sind hier die Felder bei der Übermittlung zumeist nicht fehlend, sondern als '' kodiert)
  - oder nicht in [C,D]

 klin: nur wenige Kodierungen im Datensatz aus anderen Kapiteln

 epi: In den ABC Prüfungen der epi Daten wird getestet, ob ein Diagnosecode leer ist oder ausserhalb des "Diagnosebandes" des ZfKD (konkret: A\_ICD10\_keineAuswertung[54]). Der Test ist auch im Datenbericht der epi Daten sichtbar, dort wird allerdings nur das letzte DJ herangezogen, um auf die aktuelle Entwicklung zu fokussieren.

 klin

|                  | kk_r | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|------------------|------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| diagnose_missing |      | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 4     | 393   | 0     | 0     | 148   | 545   |

Verteilung icd10 ausserhalb [C,D]: {None: 545}

 epi

|                  | kk_r | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW  | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total  |
|------------------|------|-------|-------|-------|-------|--------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|--------|
| diagnose_missing |      | 12    | 9     | 2_530 | 302   | 11_416 | 169   | 296   | 4_707 | 2_979 | 193   | 4_120 | 3_686 | 364   | 464   | 2_455 | 746   | 34_448 |

Verteilung icd10 ausserhalb [C,D]: {None: 34482}

inzidenzort\_missing

- Variable Inzidenzort fehlt, oder ist unbrauchbar kodiert (00000, 99999, oder Länge != 5)

 epi: die Variable GKZlk wird nachbearbeitet im workflow

 klin

| kkz         | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|-------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| ort_missing | 0     | 0     | 0     | 0     | 0     | 1     | 0     | 0     | 4     | 0     | 0     | 36    | 1_008 | 0     | 0     | 0     | 1_049 |

Verteilung inzidenzort missing oder ungültig{'99999': 49, None: 1000}

epi

| kkz         | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|-------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| ort_missing | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     |

Verteilung inzidenzort missing oder ungültig{}

geschlecht\_icd\_konflikt

- Widerspruch zwischen Geschlecht und Diagnose, eines der Kombinationen:
    - männlich und ['C51', 'C52', 'C53', 'C54', 'C55', 'C56', 'C57', 'C58']
    - weiblich und ['C60', 'C61', 'C62', 'C63']
- klin

| kkz                     | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|-------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| geschlecht_icd_konflikt | 1     | 0     | 3     | 0     | 7     | 0     | 5     | 5     | 7     | 1     | 6     | 3     | 0     | 0     | 1     | 1     | 40    |

Kombination Geschlecht - ICD10 ungültig: {'C61-W': 24, 'C54-M': 4, 'C56-M': 2, 'C62-W': 2, 'C51-M': 2, 'C63-W': 1, 'C57-M': 1, 'C52-M': 1, 'C53-M': 1, 'C55-M': 1, 'C58-M': 1}

epi

| kkz                     | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|-------------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| geschlecht_icd_konflikt | 1     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 0     | 1     | 5     | 3     | 0     | 0     | 1     | 0     | 11    |

Kombination Geschlecht - ICD10 ungültig: {'C61-W': 7, 'C52-M': 1, 'C56-M': 1, 'C62-W': 1, 'C63-W': 1}

datum\_missing

- Diagnosedatum oder Geburtsdatum ist leer (bzw. als Jahr 1900 kodiert)
  - nicht gesetzte Angaben zum Vitalstatus sind ignoriert
- hier sind auch regulär übermittelte Fälle mit vollständig (V) geschätztem Datum enthalten

klin

| kkz           | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|---------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| datum_missing | 17    | 36    | 78    | 21    | 1_353 | 279   | 51    | 1_286 | 1_112 | 2     | 555   | 127   | 50    | 178   | 640   | 65    | 5_850 |

Verteilung top 3 (GebDat - DiagDat): {'1900-04-01-2023-07-15': 171, '1900-04-01-2023-01-15': 169, '1900-04-01-2023-06-15': 89}

epi

| kkz           | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|---------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| datum_missing | 54    | 313   | 69    | 7     | 585   | 231   | 52    | 0     | 14    | 2_120 | 426   | 542   | 168   | 390   | 693   | 329   | 5_993 |

Verteilung top 3 (GebDat - DiagDat): {'<NA>': 155, '1932-06-15-1900-04-15': 12, '1939-10-15-1900-04-15': 12}

datum\_fehlerhaft

- Vitalstatus vor Geburt oder Diagnose vor/gleich Geburt
- alle 3 beteiligten Felder dürfen nicht missing sein

klin

| kkz              | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|------------------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| datum_fehlerhaft | 5     | 0     | 0     | 0     | 9     | 8     | 0     | 38    | 23    | 3     | 1     | 0     | 2     | 3     | 0     | 0     | 92    |

Verteilung datum\_fehlerhaft top 5:

|  | Geburtsdatum<br>date | Diagnosedatum<br>date | cnt<br>int64 |
|--|----------------------|-----------------------|--------------|
|  | 2023-03-15           | 2023-03-15            | 4            |
|  | 2020-10-15           | 2020-10-15            | 3            |
|  | 2021-01-15           | 2021-01-15            | 3            |
|  | 2022-07-15           | 2022-07-15            | 3            |
|  | 2023-01-15           | 2023-01-15            | 3            |

 epi

|                  | kk | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total |
|------------------|----|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|
| datum_fehlerhaft |    | 20    | 17    | 104   | 4     | 241   | 148   | 51    | 111   | 74    | 24    | 80    | 61    | 31    | 72    | 48    | 40    | 1_126 |

Verteilung datum\_fehlerhaft top 5:

| Geburtsdatum<br>date | Diagnosedatum<br>date | cnt<br>int64 |
|----------------------|-----------------------|--------------|
| 2013-09-15           | 2013-09-15            | 12           |
| 2013-04-15           | 2013-04-15            | 10           |
| 2019-03-15           | 2019-03-15            | 10           |
| 2019-04-15           | 2019-04-15            | 10           |
| 2013-11-15           | 2013-11-15            | 10           |

Duplikate

- Echte Duplikate stellen Fälle mit gleicher Id und gleichem hash-wert dar
- Duplikat-Verdacht: Duplikate mit gleicher Id, aber ohne inhaltliche Gleichheit sind häufiger, stellen aber lediglich eine Folge der Id Vergabe im GTDS Verbund dar. Da in der Verarbeitung eine zufällige uuid vergeben wird entstehen hier auch keine Kollisionen

Echte Duplikate

- analysiert werden Tumorfälle auf Basis gleicher Tumor\_ID (original gelieferte Id)
- ebenfalls herangezogen wird ein # hash-wert über eine Auswahl von Spalten
- haben Tumorfälle den gleichen hash-wert, kann eine inhaltliche Gleichheit angenommen werden
- Ergebnis
  - ~1000 Paare mit echten Duplikaten sind in den Daten, alle aus 09-BY.
  - keine der Paare sind innerhalb einer Lieferdatei, also keine Gefahr für die Verarbeitung
  - im Beispiel sind zwei Tumore mit gleicher originalen ID und gleichem hash-wert, aber verschiedenen Dateien
  - in allen Duplikaten werden technische ID neu vergeben, es kommt also nicht zu Kollisionen

Tests:

Für den hash-wert sind folgende Spalten herangezogen:  
Diagnose\_ICD10\_Code, Morphologie\_Code, Topographie\_Code, Geburtsdatum, Diagnosedatum, Geschlecht, Verstorben, Inzidenzort, Seitenlokalisation, T\_p, Grading, N\_p, Diagnosesicherung, M\_p

Echte Duplikate (gleiche Tumor\_ID UND gleicher Inhalt/hash):

| kk   | same_kk | same_file | cnt_cases | max_cases_in_dupl | example_Tumor_ID                           |
|------|---------|-----------|-----------|-------------------|--------------------------------------------|
| int8 | boolean | boolean   | int64     | int64             | varchar                                    |
| 9    | true    | false     | 1096      | 2                 | 00045650C5B00E9E723E8655919ABBC20F15348B_1 |

|   | z_tum_id                             | Tumor_ID                                   | z_kk | FileName                                         | sha_256                                            |
|---|--------------------------------------|--------------------------------------------|------|--------------------------------------------------|----------------------------------------------------|
| 0 | 5600d258-049d-4c77-aa32-34423e7beff8 | 00045650C5B00E9E723E8655919ABBC20F15348B_1 | 9    | .09\gtdsexpo_bayreuth_20250109_1\einzeldateie... | 16e7edabf7b78c24010bfffac5a4628a66e61426959a670... |
| 1 | de98bcd4-52df-40ad-b45f-89b1d9b9cb9a | 00045650C5B00E9E723E8655919ABBC20F15348B_1 | 9    | .09\gtdsexpo_erlangen_20250110_1\einzeldateie... | 16e7edabf7b78c24010bfffac5a4628a66e61426959a670... |

Duplikatverdacht


- die originale Tumor\_ID wird hier ignoriert
  - es wird für alle Tumorfälle geprüft, ob es Fälle mit gleicher Kombination verschiedener Merkmale gibt
  - Verdachtsfälle mit gleicher Kombination aus verschiedenen Registern und Patienten sind möglich
  - die Übereinstimmungswahrscheinlichkeit steigt deutlich, wenn mehr Merkmale leer sind
- Verwendete Merkmale: Diagnose\_ICD10\_Code, Morphologie\_Code, Topographie\_Code, Geburtsdatum, Diagnosedatum, Geschlecht, Verstorben, Inzidenzort, Seitenlokalisation, T\_p, Grading, N\_p, Diagnosesicherung, M\_p
-  klin

|                   | kk | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total  |
|-------------------|----|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|--------|
| duplikat_verdacht |    | 60    | 664   | 571   | 40    | 1_060 | 260   | 158   | 631   | 3_100 | 30    | 2_118 | 192   | 347   | 370   | 348   | 488   | 10_437 |

 epi

|                   | kk | 01-SH | 02-HH | 03-NI | 04-HB | 05-NW | 06-HE | 07-RP | 08-BW | 09-BY | 10-SL | 11-BE | 12-BB | 13-MV | 14-SN | 15-ST | 16-TH | Total  |
|-------------------|----|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|-------|--------|
| duplikat_verdacht |    | 528   | 2_100 | 8_071 | 197   | 5_197 | 1_742 | 2_670 | 1_373 | 2_191 | 850   | 5_621 | 1_031 | 594   | 1_885 | 1_373 | 1_067 | 36_490 |

Verteilung nach Inzidenzort




epi

Verteilung nach Diagnosejahr




## TOP 20 [cnt] by [DJ], n=35 (10\_437)



epi


## TOP 20 [cnt] by [DJ], n=57 (36\_512)



## Verteilung nach ICD10


klin

TOP 10 [cnt] by [icd10\_3d], n=87 (10\_437)



epi

TOP 10 [cnt] by [icd10\_3d], n=103 (36\_512)



Verteilung der Gruppen mit gleichen Merkmalen

- "Gruppe" = >1 Verdachtsfälle mit gleichen Merkmalen
- verwendete Metriken (jeweils aufgetragen: `is_equal` = "alle Fälle in der Gruppe haben den gleichen Wert")

es gibt wenige Gruppen, in denen die Duplikate aus verschiedenen kkr stammen  
in den meisten Gruppen stammen die Duplikate nicht von einem einzelnen Patienten

**klin**

10\_437 Fälle verteilen sich auf 5\_103 Gruppen mit max 4 Fällen in einer Gruppe

Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: REGISTER {True: 4903, False: 200}

Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: PATIENTID {False: 4470, True: 633}

**epi**

36\_512 Fälle verteilen sich auf 18\_022 Gruppen mit max 6 Fällen in einer Gruppe

Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: REGISTER {True: 18022}

Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: PATIENTID {False: 16671, True: 1351}