

Ableiten des epi Datensatzes für die ehemaligen GKR Länder aus den klinischen Daten

Table of contents

- Ableiten des epi Datensatzes für die ehemaligen GKR Länder aus den klinischen Daten
 - Zusammenfassung 
 - load data
 - Datenstand 
 - Verteilungen in den Teildatensätzen
 - Fallzahlen bei cut-off DJ 2020

Zusammenfassung

- Ziel des Algorithmus ist es, die epi Daten für die ehemaligen GKR Länder zu erzeugen
- Für die DJ vor 2020 liegt ein Archiv der GKR Daten vor. Diese Daten wurden bis **epi2022** verwendet
- Für die DJ nach 2020 sollen epi Daten aus dem aktuellen Stand der klinischen Daten abgeleitet werden
- angewendete Regeln
 - GKR Archiv wird bis inkl. DJ 2019 verwendet
 - für die klinischen Daten (Stand Juli 2024, DJ 2022 flächendeckend enthalten):
 - Filter nach kkr 11-16 ("nur GKR Länder")
 - über eine Auswahl von Spalten der Daten werden Duplikate ermittelt, also alle Fälle mit gleichen Ausprägungen dieser Spalten. (Details siehe Dokument: **Technische Prüfungen in klinischen und epi Daten**). Von den Duplikaten wird jeweils nur ein zufälliger Fall übernommen (in den klinischen Daten selbst erfolgt keine Löschung von Daten)
 - beide Teildatensätze werden in das originale Lieferschema der GKR überführt, und in den workflow integriert

load data



 3.12.2 |  pandas: 2.2.2 |  numpy: 1.26.4 |  duckdb: 1.0.0 |  pandas-plots: 0.11.4 |  connection_helper: 0.7.2

Datenstand

```
last kkr data import:    2024-06-25 11:34:17
last sql data fetch:    2024-06-25 11:47:11
notebook run at:        2024-07-10 08:21:12
Stand der epi Daten ist batch  396, als letzter Datenstand vor Erzeugung der GKR epi Daten
```

Verteilungen in den Teildatensätzen

- jeweils für das GKR Archiv und die klin. Daten ohne Duplikate sind die aktuellsten DJ aufgespannt nach Lieferregister (im GKR Archiv ist dafür näherungsweise die GKZ verwendet, hier ist das Lieferregister immer 11)
- ein cut-off bei DJ 2020 erscheint günstig, da die Verteilung / Beschaffenheit für die Jahresscheiben 2020ff in den klin. Daten realistischer erscheint als im GKR Archiv



Fallzahlen bei cut-off DJ 2020

Anzahl Fälle GKR Archiv vor 2020:	3_268_256
Anzahl Fälle GKR Länder aus klin. Daten ab 2020:	499_744
└─ nach Duplikatbereinigung:	488_393