

Bericht zur Datenqualität (klin)

Table of contents

- Bericht zur Datenqualität (klin) 
 - Änderungen seit der letzten Version
 - Datenstand 
 - Lieferdatum 
 - Fallzahlen
 - absolut
 - relativ
 - missings
 - Fallzahlen epi vs clin
 - Verteilung von Variablen
 - UICC (p)
 - Diagnosesicherung
 - Geschlecht
 - Diagnosejahr
 - Inzidenzort vs Lieferregister
 - ICD10 Gruppen
 - Verstorben
 - TNM-T (p)
 - TNM-N (p)
 - TNM-M (p)
 - TNM-Auflage (p)
 - Todesursachen (TU)
 - nach ICD10 Einstellern
 - nach Sterbejahr und Todesursachen
 - nach hat_todesursache bei Nicht-Verstorbenen
 - nach ICD10 Dreistellern (TOP 5)
 - nach IsGrundleiden
 - OP
 - nach ICD10
 - nach Intention
 - OPS
 - nach OPS ICD Kapitel (Top 10)
 - nach OPS Einzelcodes (Top 5)
 - SYST
 - nach Stellung_OP
 - Missings / Unbekannt in den Daten
 - Missings für verpflichtende Variablen in Tumor Element
 - Missings für Therapieangaben
 - Missings für Tumorstadien
 - Missings für organspezifische Variablen (Mamma)
 - Missings für organspezifische Variablen (Prostata)
 - Missings für organspezifische Variablen (Darm)
 - Missings für organspezifische Variablen (Melanom)
 - Missings für Prio Variablen
 - Unbekannt für verpflichtende Variablen
 - Verteilung Monat von DatumVitalstatus
 - Numerische Variablen 
 - Diagnosealter
 - Anzahl Tage zwischen Diagnose und Tod
 - Tumordicke
 - PSA
 - LK_befallen
 - LK_untersucht
 - RektumAbstandAnokutanlinie
 - LDH

Änderungen seit der letzten Version

- Neulieferung 06-HE
- Numerische Variablen  enthalten nun mehr Diagramme

Datenstand

```
import os
from pathlib import Path
import pandas as pd
import duckdb as ddb
from connection_helper import sql
from pandas_plots import tbl, pls, hlp
from enum import Enum
import duckdb as ddb

hlp.show_package_version()
os.environ['THEME']='light'

dir_db=Path("C://temp") if hlp.get_os(hlp.OperatingSystem.WINDOWS) else Path(os.path.expanduser("~/tmp"))
file_db_clin = dir_db/'workFlow/2025-10-20_data_clin.duckdb'
file_db_intern = dir_db/'workFlow/2025-10-20_internal_clin.duckdb'
file_db_epi = dir_db/'2025-06-20_data_epi.duckdb'
URL_V2 = 'https://gitlab.opencode.de/robert-koch-institut/zentrum-fuer-krebsregisterdaten/cancerdata-references/-/raw/main/data/v2/'

if not file_db_clin.exists() or not file_db_epi.exists() or not file_db_intern.exists():
    raise FileNotFoundError()
```

 3.12.8 |  pandas: 2.3.3 |  numpy: 1.26.4 |  duckdb: 1.4.1 |  pandas-plots: 0.20.2 |  connection-helper: 0.13.1

```
sql.print_meta(file_db_clin)
```

```
sqlite db file:      2025-10-20_data_clin.duckdb
data tag:            v2.3
last kkr data import: 2025-09-30
sql table created:   2025-10-20 18:49:45
doi:                 10.18444/5.03.01.0005.0021.0001
document created:    2025-10-27 12:26:26
```

```
con = ddb.connect()
_=con.execute("PRAGMA disable_progress_bar;")
_=con.execute(f"ATTACH DATABASE '{file_db_epi}' AS epi (READ_ONLY);")
_=con.execute(f"ATTACH DATABASE '{file_db_intern}' AS intern (READ_ONLY);")
_=con.execute(f"ATTACH DATABASE '{file_db_clin}' AS clin (READ_ONLY); SET SCHEMA 'clin';")
```

```
dim_icd10_3d = sql.load_file_to_duckdb(con, URL_V2 + "Aggregationen/icd10_3d.csv", sep=";")
dim_syst_op_stellung = sql.load_file_to_duckdb(con, URL_V2 + "Klassifikationen/syst_op_stellung.csv", sep=";")

Applikationsart = con.sql("select * from clin.Applikationsart")
Bestrahlung = con.sql("select * from clin.Bestrahlung")
Diagnose_Fernmetastase = con.sql("select * from clin.Diagnose_Fernmetastase")
Diagnose>WeitereKlassifikation = con.sql("select * from clin.Diagnose>WeitereKlassifikation")
Folgeereignis = con.sql("select * from clin.Folgeereignis")
Folgeereignis_Fernmetastase = con.sql("select * from clin.Folgeereignis_Fernmetastase")
Folgeereignis_TNM = con.sql("select * from clin.Folgeereignis_TNM")
Folgeereignis>WeitereKlassifikation = con.sql("select * from clin.Folgeereignis>WeitereKlassifikation")
Lieferung = con.sql("select * from clin.Lieferung")
OP = con.sql("select * from clin.OP")
OPS = con.sql("select * from clin.OPS")
Protokoll = con.sql("select * from clin.Protokoll")
ST = con.sql("select * from clin.ST")
SYST= con.sql("select * from clin.SYST")
Substanz = con.sql("select * from clin.Substanz")
Todesursache = con.sql("select * from clin.Todesursache")
_meta = con.sql("select * from clin._meta")
Tumor = con.sql("select * from clin.Tumor")
Patient = con.sql("select * from clin.Patient")

dim_lieferregister = con.sql("select * from clin.dim_lieferregister")
dim_tnm_t = con.sql("select * from clin.dim_tnm_t")
dim_tnm_uicc = con.sql("select * from clin.dim_tnm_uicc")
dim_dsich_clin = con.sql("select * from clin.dim_diagnosesicherung_clin")
dim_op_intention = con.sql("select * from clin.dim_op_intention")

dim_tree = sql.load_file_to_duckdb(con, "../quality-reports/data/dim/tree.csv", sep=";")

_treecompletion = con.sql("select * from intern._treecompletion").project('*', Diagnose_ICD10_Code_DREI as icd10_3d').project('* exclude
(Diagnose_ICD10_Code_DREI)')

# * epi (Fallzahlen)
Tumor4 = con.sql("select * from epi.Tumor4")#.project("*, case when IARC like '%A_%' then cast(1 as int16) else cast(0 as int16) end as is_deleted")
```

```
# # ! settings
class grouper_reg(Enum):
    KKR = "kkr"
    SYSTEM = "system"
    TOTAL = "Total"

class kpi(Enum):
    MISSINGS = "kpi_missing"
    UNKNOWNN = "kpi_unknown"

class grouper_table(Enum):
    TABLECOL = "tablecolumn"
    TABLES = "tables"

dy_max = 2023

fil_pd_dco_dy=f"dco=0 and dj_clipped>2019 and dj_clipped <= {dy_max}"
fil_pd_c44 = "icd10_3d <> 'C44'"

fil_dy = f"z_dy > 2019 and z_dy <= {dy_max}"
fil_dy_no_c44_no_dco = f"{fil_dy} and not z_is_dco and icd10_3d <> 'C44'"
fil_dy_no_solid_no_dco = f"{fil_dy} and not z_is_dco and is_solid"
```

Lieferdatum

- **kkr** = Klinisches Krebsregister
- **Lieferdatum** = Datum der letzten Übermittlung durch die KKR
- **Diagnosemonat** = letzter Diagnosemonat in den Daten

```
_tu_latest = Tumor.filter(f"z_dy = {dy_max}").aggregate("z_kkr_label, count(*) as cnt")

_tu=(Tumor.set_alias("t")
    .join(Lieferung.set_alias("l"), "l.Lieferregister::int = t.z_kkr::int", "inner")
    .aggregate("t.z_kkr_label, left(cast(max(Diagnosedatum) as varchar),7) as Diagnosemonat, max(Lieferdatum) as Lieferdatum")
    .join(_tu_latest.set_alias("latest"), "z_kkr_label", "left")
    # .project("z_kkr_label, Diagnosemonat")
    .order("z_kkr_label")
    .to_df().set_index("z_kkr_label")
    .astype({"Lieferdatum":str})
    .assign(Tumorfälle_2023 = lambda x: x["cnt"].apply(lambda y: f"{y:_0f}"))
    .drop(columns=["cnt"])
    .T
)
display(_tu)
# con.from_df(_tu.reset_index()).show()
```

z_kkr_label	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
Diagnosemonat	2023-12	2023-12	2023-12	2023-12	2023-12	2025-04	2023-12	2024-12	2024-12	2023-12	2025-01	2025-01	2025-01	2023-12	2024-11	2023-12
Lieferdatum	2025-01-06	2025-01-29	2025-01-08	2025-02-04	2025-02-23	2025-05-27	2025-02-21	2025-09-30	2025-01-10	2025-02-13	2025-03-10	2025-03-10	2025-01-21	2025-01-13	2025-01-29	2025-02-28
Tumorfälle_2023	36_066	13_937	48_361	5_251	202_729	40_386	28_342	90_457	91_020	10_697	27_295	22_556	23_661	56_030	25_326	15_869

Fallzahlen

- in den Darstellungen sind keine Filter angewendet, solange nicht explizit angegeben

absolut

- aufgespannt sind die Fallzahlen für Lieferregister und Elementknoten
- für jedes Register ist hier insbesondere einsehbar, wie viele Tumore/Patienten aus der aktuellsten Lieferung verarbeitet wurden
- kein Filter, "Altfälle" (DJ < 2020) sind also enthalten
- aufgeteilt auf 2 Tabellen zur besseren Übersicht
- die % Werte sowie die farbigen Datenbalken zeigen das relative Gewicht jedes KKR an "D gesamt" (Total Zeile)
- Erklärung für einige Elementknoten: (_cnt = count/Fallzahl)

- `weitere_diag_cnt` = Weitere Klassifikation im Elementknoten "Diagnose"
- `weitere_folge_cnt` = Weitere Klassifikation im Elementknoten "Folgeereignis"
- `fm_folge_cnt` = Fernmetastasen im Elementknoten "Folgeereignis"
- `fm_diag_cnt` = Fernmetastasen im Elementknoten "Diagnose"
- `tnm_folge_cnt` = TNM im Elementknoten "Folgeereignis"

🔗 ZfKD: "die absoluten Werte lassen erkennen, dass inzwischen die meisten Elemente flächendeckend vorliegen. Ausnahmen: Applikationsart, Folgeereignisse, Protokolle / Substanzen"

```
with open("sql/clin_data.sql") as f:
    sql_clin_data = f.read()
db_clin_all = (con
    .sql(sql_clin_data)
    .join(dim_icd10_3d, "icd10_3d = code", "left")
    .project("* exclude (code)")
    .project("* replace (bl::tinyint as bl)")
)
# tbl.descr_db(db_clin_all, "db_clin_all")
```

```
col_count_str = [
    f"sum({col}) as {col}" for col in db_clin_all.columns if (col.endswith("_cnt"))
]
col_missing_str = [
    f"sum({col}) as {col}" for col in db_clin_all.columns if col.endswith("_missing")
]

def get_absolute_cases(
    db_all,
    cols: list[str],
    group=grouper_reg.KKR.value,
    filter: str = "",
    total_include: bool = False,
):
    # * empty filter must be neutral in the query
    if not filter:
        filter = "True"

    # * is executed twice
    def get_db(group: str):
        _project = "'Total' as Total, *" if group == grouper_reg.TOTAL.value else "*"
        return (
            db_all.filter(filter)
            .project(_project)
            .aggregate(
                f"""--sql
                {group},
                count(*) as tum_cnt,
                count(distinct pat_id) as pat_cnt,
                {''.join(cols)},
                """
            )
            .order(group)
        )

    db = get_db(group)
    if group != grouper_reg.TOTAL.value and total_include:
        db = db.union(get_db(grouper_reg.TOTAL.value))
    return db

def get_relative_cases(
    db_all, group=grouper_reg.KKR.value, filter: str = "", total_include: bool = False
):
    db_abs = get_absolute_cases(
        db_clin_all,
        cols=col_count_str,
        group=group,
        filter=filter,
        total_include=total_include,
    )
    db_rel = db_abs.aggregate(
        f"""--sql
        {group},
        sum(tum_cnt)/sum(pat_cnt) as tum_per_pat,
        sum(op_cnt)/sum(tum_cnt) as op_per_tum,
        sum(ops_cnt)/sum(tum_cnt) as ops_per_tum,
        sum(st_cnt)/sum(tum_cnt) as st_per_tum,
        sum(syst_cnt)/sum(tum_cnt) as syst_per_tum,
        sum(folge_cnt)/sum(tum_cnt) as folge_per_tum,
        """
    ).order(group)
    df = db_rel.to_df().set_index(group)
    return df

def get_missing_cases(db_all, group=grouper_reg.KKR.value, filter: str = "", total_include: bool = False):
    db_abs = get_absolute_cases(
        db_clin_all, cols=col_missing_str, group=group, filter=filter, total_include=total_include
    )
    db_miss = db_abs.aggregate(
        f"""--sql
        {group},
        sum(op_missing)/sum(tum_cnt) as op_missing_per_tum,
        sum(st_missing)/sum(tum_cnt) as st_missing_per_tum,
        sum(syst_missing)/sum(tum_cnt) as syst_missing_per_tum,
        sum(folge_missing)/sum(tum_cnt) as folge_missings_per_tum,
        sum(thera_missing)/sum(tum_cnt) as treat_missing_per_tum,
        """
    ).order(group)
    df = db_miss.to_df().set_index(group)
    return df
```

```
db_cases_abs = get_absolute_cases(
    db_clin_all, group=grouper_reg.KKR.value, cols=col_count_str, total_include=False
)
_tu = db_cases_abs.to_df().set_index("kkr")[
    "tum_cnt",
    "pat_cnt",
    "op_cnt",
    "ops_cnt",
    "syst_cnt",
    "st_cnt",
    "bestr_cnt",
    "app_cnt",

    "weitere_diag_cnt",
    "fm_diag_cnt",
    "folge_cnt",
    "weitere_folge_cnt",
    "fm_folge_cnt",
    "tnm_folge_cnt",
    "proto_cnt",
    "subst_cnt",
]
tbl.show_num_df(
    _tu.iloc[:, :8],
    data_bar_axis="x",
    total_axis="x",
    pct_axis="x",
    # kpi_mode="max_min_x",
)
```

	tum_cnt	pat_cnt	op_cnt	ops_cnt	syst_cnt	st_cnt	bestr_cnt	app_cnt
kkr								
01-SH	150_685 (4.6%)	136_279 (5.0%)	44_826 (2.7%)	86_663 (2.8%)	39_951 (3.6%)	20_343 (4.0%)	20_343 (3.3%)	0
02-HH	55_559 (1.7%)	51_555 (1.9%)	33_147 (2.0%)	61_766 (2.0%)	31_235 (2.8%)	12_733 (2.5%)	16_630 (2.7%)	16_630 (3.2%)
03-NI	216_710 (6.7%)	201_385 (7.4%)	95_021 (5.7%)	197_982 (6.3%)	99_259 (9.0%)	41_667 (8.3%)	41_667 (6.8%)	0
04-HB	25_182 (0.8%)	22_954 (0.8%)	9_265 (0.6%)	21_345 (0.7%)	10_564 (1.0%)	4_354 (0.9%)	4_354 (0.7%)	0
05-NW	805_679 (24.9%)	746_553 (27.3%)	355_202 (21.5%)	713_974 (22.7%)	219_790 (19.9%)	76_685 (15.3%)	102_951 (16.9%)	102_951 (20.0%)
06-HE	174_565 (5.4%)	153_528 (5.6%)	92_019 (5.6%)	198_038 (6.3%)	72_866 (6.6%)	31_072 (6.2%)	43_886 (7.2%)	43_886 (8.5%)
07-RP	123_111 (3.8%)	112_755 (4.1%)	57_912 (3.5%)	108_047 (3.4%)	39_125 (3.5%)	22_834 (4.5%)	22_834 (3.7%)	0
08-BW	362_189 (11.2%)	322_201 (11.8%)	228_012 (13.8%)	464_617 (14.8%)	111_974 (10.1%)	82_173 (16.3%)	97_115 (15.9%)	97_115 (18.9%)
09-BY	431_813 (13.3%)	343_452 (12.6%)	226_367 (13.7%)	421_347 (13.4%)	156_584 (14.2%)	77_356 (15.4%)	94_487 (15.5%)	93_652 (18.2%)
10-SL	48_061 (1.5%)	43_489 (1.6%)	16_312 (1.0%)	31_262 (1.0%)	15_211 (1.4%)	6_693 (1.3%)	6_693 (1.1%)	0
11-BE	114_910 (3.5%)	102_652 (3.8%)	73_421 (4.4%)	158_694 (5.0%)	50_167 (4.5%)	22_942 (4.6%)	27_482 (4.5%)	27_482 (5.4%)
12-BB	104_299 (3.2%)	85_150 (3.1%)	64_795 (3.9%)	124_370 (4.0%)	49_344 (4.5%)	22_240 (4.4%)	26_587 (4.4%)	26_587 (5.2%)
13-MV	110_032 (3.4%)	75_219 (2.8%)	73_292 (4.4%)	105_958 (3.4%)	38_061 (3.4%)	15_609 (3.1%)	19_044 (3.1%)	19_044 (3.7%)
14-SN	300_228 (9.3%)	187_586 (6.9%)	127_756 (7.7%)	205_189 (6.5%)	90_596 (8.2%)	34_876 (6.9%)	42_037 (6.9%)	42_037 (8.2%)
15-ST	126_193 (3.9%)	88_787 (3.2%)	88_209 (5.3%)	150_496 (4.8%)	46_147 (4.2%)	17_570 (3.5%)	24_470 (4.0%)	24_470 (4.8%)
16-TH	92_185 (2.8%)	61_607 (2.3%)	69_115 (4.2%)	98_012 (3.1%)	35_347 (3.2%)	13_523 (2.7%)	19_631 (3.2%)	19_631 (3.8%)
Total	3_241_401 (100.0%)	2_735_152 (100.0%)	1_654_671 (100.0%)	3_147_760 (100.0%)	1_106_221 (100.0%)	502_670 (100.0%)	610_211 (100.0%)	513_485 (100.0%)

```
tbl.show_num_df(
    _tu.iloc[:, 8:],
    data_bar_axis="x",
    total_axis="x",
    pct_axis="x",
    # kpi_mode="max_min_x",
)
```

	weitere_diag_cnt	fm_diag_cnt	folge_cnt	weitere_folge_cnt	fm_folge_cnt	tnm_folge_cnt	proto_cnt	subst_cnt
kkr								
01-SH	10_991 (1.9%)	20_491 (4.2%)	0	0	0	0	0	0
02-HH	14_732 (2.6%)	18_160 (3.7%)	10_849 (0.5%)	0	1_124 (0.5%)	10_849 (0.5%)	31_235 (5.1%)	73_168 (4.3%)
03-NI	42_158 (7.3%)	47_648 (9.7%)	0	0	0	0	0	0
04-HB	3_419 (0.6%)	6_231 (1.3%)	0	0	0	0	0	0
05-NW	73_844 (12.9%)	75_618 (15.4%)	518_395 (22.9%)	84_781 (70.2%)	34_296 (16.0%)	518_395 (22.9%)	42_452 (6.9%)	435_310 (25.6%)
06-HE	37_730 (6.6%)	33_816 (6.9%)	167_564 (7.4%)	7_558 (6.3%)	12_506 (5.8%)	167_564 (7.4%)	72_861 (11.9%)	138_412 (8.1%)
07-RP	9_624 (1.7%)	13_677 (2.8%)	32_555 (1.4%)	0	6_738 (3.1%)	32_555 (1.4%)	0	0
08-BW	188_128 (32.8%)	68_967 (14.1%)	690_503 (30.5%)	4_332 (3.6%)	69_701 (32.5%)	690_503 (30.5%)	0	243_297 (14.3%)
09-BY	50_090 (8.7%)	65_503 (13.4%)	224_216 (9.9%)	14_374 (11.9%)	35_862 (16.7%)	224_216 (9.9%)	156_343 (25.5%)	276_299 (16.2%)
10-SL	14_362 (2.5%)	7_964 (1.6%)	0	0	0	0	0	0
11-BE	22_609 (3.9%)	27_544 (5.6%)	58_847 (2.6%)	458 (0.4%)	8_147 (3.8%)	58_847 (2.6%)	50_166 (8.2%)	94_598 (5.6%)
12-BB	19_989 (3.5%)	23_298 (4.8%)	59_362 (2.6%)	367 (0.3%)	8_495 (4.0%)	59_362 (2.6%)	49_344 (8.1%)	88_186 (5.2%)
13-MV	13_994 (2.4%)	13_453 (2.7%)	143_143 (6.3%)	5_889 (4.9%)	7_598 (3.5%)	143_143 (6.3%)	38_043 (6.2%)	54_318 (3.2%)
14-SN	36_914 (6.4%)	36_866 (7.5%)	136_602 (6.0%)	984 (0.8%)	16_772 (7.8%)	136_602 (6.0%)	90_592 (14.8%)	157_546 (9.3%)
15-ST	21_144 (3.7%)	17_770 (3.6%)	132_483 (5.8%)	1_322 (1.1%)	7_603 (3.5%)	132_483 (5.8%)	46_146 (7.5%)	82_339 (4.8%)
16-TH	14_220 (2.5%)	13_357 (2.7%)	90_481 (4.0%)	697 (0.6%)	5_886 (2.7%)	90_481 (4.0%)	35_344 (5.8%)	57_016 (3.4%)
Total	573_948 (100.0%)	490_363 (100.0%)	2_265_000 (100.0%)	120_762 (100.0%)	214_728 (100.0%)	2_265_000 (100.0%)	612_526 (100.0%)	1_700_489 (100.0%)

relativ

- Filter: DJ = 2020-2023, DC0 = N, ICD16 != C44
- der Filter ist gewählt, um eine bessere Vergleichbarkeit der Werte zu gewährleisten

- die Metriken sind **einfache Verhältniszahlen**, z.B: **op_per_tum** = alle OP / alle Tumore (pro kkr)
- es sind jeweils die kumulierten Werte aufgespannt:
 - nach einzelnen **Lieferregistern**
 - nach verwendeten **Tumordokumentationssystemen** (um systemische Effekte darstellen zu können)

```
_tu = get_relative_cases(db_clin_all, group=grouper_reg.KKR.value, filter=fil_dy_no_c44_no_dco, total_include=True)
tbl.show_num_df(
    _tu,
    data_bar_axis="xy",
    total_axis="",
    pct_axis="",
    precision=2,
    # kpi_mode="min_max_x",
    # total_exclude=True,
)
```

	tum_per_pat	op_per_tum	ops_per_tum	st_per_tum	syst_per_tum	folge_per_tum
kkf						
01-SH	1.07	0.42	0.81	0.19	0.38	0
02-HH	1.07	0.61	1.15	0.24	0.58	0.20
03-NI	1.08	0.44	0.91	0.19	0.46	0
04-HB	1.08	0.45	1.04	0.21	0.52	0
05-NW	1.06	0.58	1.19	0.14	0.39	0.84
06-HE	1.06	0.54	1.16	0.18	0.44	0.93
07-RP	1.09	0.47	0.88	0.19	0.33	0.27
08-BW	1.11	0.63	1.32	0.24	0.34	2.04
09-BY	1.06	0.66	1.24	0.23	0.47	0.65
10-SL	1.09	0.45	0.89	0.20	0.45	0
11-BE	1.06	0.72	1.55	0.22	0.49	0.57
12-BB	1.06	0.75	1.45	0.26	0.58	0.69
13-MV	1.07	0.76	1.20	0.23	0.58	1.85
14-SN	1.07	0.77	1.26	0.24	0.63	0.89
15-ST	1.05	0.69	1.37	0.23	0.61	1.58
16-TH	1.06	0.82	1.31	0.25	0.66	1.22
Total	1.07	0.60	1.19	0.20	0.45	0.85

```
_tu = get_relative_cases(db_clin_all, group=grouper_reg.SYSTEM.value, filter=fil_dy_no_c44_no_dco, total_include=True)
tbl.show_num_df(_tu, data_bar_axis="xy", total_axis="", pct_axis="", precision=2)
```

	tum_per_pat	op_per_tum	ops_per_tum	st_per_tum	syst_per_tum	folge_per_tum
system						
Total	1.07	0.60	1.19	0.20	0.45	0.85
gtlds	1.06	0.69	1.29	0.23	0.52	0.89
nw	1.06	0.58	1.19	0.14	0.39	0.84
rp	1.09	0.47	0.88	0.19	0.33	0.27
tristan	1.08	0.43	0.89	0.19	0.44	0
tristan_bw	1.11	0.63	1.32	0.24	0.34	2.04
tristan_hh	1.07	0.61	1.15	0.24	0.58	0.20

missings

- **Filter: DJ = 2020-2023, DCO = N, ICD10 nur solide Tumoren** (solide Tumoren schliesst folgende Diagnosen aus: C44, C70-C72, C76-C97, alle D)
- ein Wert von bspw. 0.68 ist zu interpretieren als: "68% aller Tumorfälle im KKR haben keine zugeordneten OP Angaben, die restlichen 32% mindestens eine."
- **treat_missing_per_tum** stellt den Anteil Fälle dar, bei denen keinerlei Therapieangabe (OP, ST, SYST) vorliegt
- in der Darstellung sind die Max/Min Werte pro Kennzahl mit   markiert (kleiner ist besser)

🔍 **NI:** "Die **Missings für Folgeereignis, Strahlentherapie und Systemische Therapie** sind Resultat der noch ausstehenden Implementierung in der Registersoftware Tristan zur Bildung der jeweiligen Best-Of-Informationen. Die Implementierung ist bereits beauftragt. Neben Niedersachsen nutzen die Bundesländer Schleswig-Holstein, Bremen und das Saarland dieselbe Tristan-Implementierung"

🔍 **ZfKD:** "aus **st_missing_per_tum** lässt sich ablesen, dass ~23% der Tumoren deutschlandweit mind. eine ST zugeordnet ist (Total: 1 - 0.77 = 0.23). Das entspricht in etwa der Annahme von 30% Anteil von Strahlentherapien an primären Diagnosen"

```
_tu = get_missing_cases(db_clin_all, group=grouper_reg.KKR.value, filter=fil_dy_no_solid_no_dco, total_include=True)
tbl.show_num_df(_tu, data_bar_axis="xy", total_axis="", pct_axis="", precision=2, kpi_mode="min_max_x", total_exclude=True)
# todo treat nach dy aufspannen
```

	op_missing_per_tum	st_missing_per_tum	syst_missing_per_tum	folge_missings_per_tum	treat_missing_per_tum
kkf					
01-SH	0.48 	0.74 	0.67 	1.00 	0.25 
02-HH	0.43 	0.73 	0.70 	0.82 	0.24 
03-NI	0.50 	0.78 	0.69 	1.00 	0.30 
04-HB	0.45 	0.72 	0.61 	1.00 	0.23 
05-NW	0.47 	0.84 	0.71 	0.65 	0.31 
06-HE	0.51 	0.80 	0.72 	0.54 	0.34 
07-RP	0.54 	0.79 	0.72 	0.80 	0.34 
08-BW	0.46 	0.74 	0.64 	0.46 	0.26 

	op_missing_per_tum	st_missing_per_tum	syst_missing_per_tum	folge_missings_per_tum	treat_missing_per_tum
kkp					
09-BY	0.43	0.76	0.71	0.62	0.25
10-SL	0.49	0.76	0.64	1.00	0.29
11-BE	0.41	0.74	0.65	0.62	0.21
12-BB	0.39	0.71	0.61	0.58	0.18
13-MV	0.37	0.71	0.60	0.27	0.17
14-SN	0.36	0.72	0.59	0.52	0.15
15-ST	0.42	0.74	0.61	0.26	0.21
16-TH	0.34	0.72	0.59	0.47	0.16
Total	0.45	0.77	0.68	0.64	0.27

```
_tu = get_missing_cases(db_clin_all, group=grouper_reg.SYSTEM.value, filter=fil_dy_no_solid_no_dco, total_include=True)
tbl.show_num_df(_tu, data_bar_axis="xy", total_axis="", pct_axis="", precision=2, kpi_mode="min_max_x", total_exclude=True)
```

	op_missing_per_tum	st_missing_per_tum	syst_missing_per_tum	folge_missings_per_tum	treat_missing_per_tum
system					
Total	0.45	0.77	0.68	0.64	0.27
gtlds	0.42	0.75	0.66	0.54	0.23
nw	0.47	0.84	0.71	0.65	0.31
rp	0.54	0.79	0.72	0.80	0.34
tristan	0.49	0.76	0.68	1.00	0.28
tristan_bw	0.46	0.74	0.64	0.46	0.26
tristan_hh	0.43	0.73	0.70	0.82	0.24

Fallzahlen epi vs clin

- Filter: DJ = 2023, DCO = N, ICD10 != C44, Inzidenzort(BL) = Register
 - Ziel der Darstellung: Abschätzung der Vollständigkeit der klinischen Daten
 - dargestellt sind die gefilterten Fallzahlen jeweils aus den epi und den klinischen Daten, hier allerdings nur aus dem letzten DJ 2023
 - Hinweis: Die Auswertung Daten basiert auf Inzidenzort anstatt Lieferregister, da in den epi Daten bislang die einzelnen Länder des GKR nicht aufgeschlüsselt waren, und ein matching auf EKRNR somit fehlschlägt
- ⚠ NI: "Die höhere Fallzahl des epidemiologischen Registers im Vergleich zum klinischen Register ist vermutlich auf unterschiedliche Filterkriterien in den beiden Registern zurückzuführen. Im KKN werden neben den Kriterien die das Lieferschema vorgibt auch noch weitere Plausibilitätsprüfungen angewandt. Tumoren, welche diese Prüfungen nicht bestehen, werden vom Export ausgeschlossen"

⚠ ZfKD: "Die quota in den anderen KKR entspricht der Erwartung, dass die Fallzahl bei klin. Daten höher sein sollte als bei epi Daten. Beim Vergleich der ehemaligen GKR Länder entstehen prozessbedingt Artefakte, welche das Ergebnis leicht verfälschen. Die Fallzahl bei den epi Daten kann nicht höher sein, da diese aus den klinischen Daten generiert wurden."

```
_db2=(db_clin_all
# .filter("left(kkr,2) = bl and bl::int between 1 and 16") # * very few cases
.filter(f"z_dy in ({dy_max})")
.filter(f"left(icd10,3) <> 'C44' and not z_is_dco")
.aggregate("bl, count(*) as clin_cnt")
.join(dim_lieferregister.set_alias("l"), "bl::int8 = l.code", "inner")
.project("bl,clin_cnt")
)

_db1=(Tumor4
# .project("*, case when left(GKZlk,2)::int > 10 then left(GKZlk,2) else EKRNR end as EKRNR_")
# .filter("EKRNR_ = left(GKZlk,2) and left(GKZlk,2)::int between 1 and 16")
.filter(f"DJ in ({dy_max}) and not is_deleted")
.filter("left(ICDGM10,3) <> 'C44' and DCO = 2")
.aggregate("left(GKZlk,2) as bl, count(*) as epi_cnt")
)

_df12 = _db1.join(_db2, "bl", "right").to_df()

_tu = (
_df12.merge(dim_lieferregister.to_df(), left_on="bl", right_on="code")
.assign(quota=lambda x: x.clin_cnt / x.epi_cnt * 100)
.set_index("kkr")[["clin_cnt", "epi_cnt", "quota"]]
.sort_index(ascending=True)
.T
)
tbl.show_num_df(_tu.fillna(0), total_mode="")
```

kkp	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
clin_cnt	25_481	13_121	48_277	4_691	140_041	39_467	27_715	83_186	85_344	7_992	24_742	20_901	15_391	36_244	17_194	11_910
epi_cnt	23_920	12_701	60_704	4_533	139_870	39_146	27_415	73_780	80_381	7_986	23_705	19_638	14_766	34_932	16_251	11_361
quota	107	103	80	103	100	101	101	113	106	100	104	106	104	104	106	105

Verteilung von Variablen

- in den Diagrammen gibt das angegebene *n*= einen Hinweis auf die verwendete Grundgesamtheit
- die relativen Barcharts enthalten ein **Total** item für den Gesamtvergleich

```
def show_vars(idx: int, group_reg: str, show: bool = True, filter: str = ""):
    agg_counts = {"pat": "distinct oBDS_RKIPatientId", "tum": "*"}
    agg_cols = [
        ["Geschlecht", "pat"],
        ["Verstorben", "pat"],
        ["UICC_Stadium_p", "tum"],
        ["Diagnosesicherung", "tum"],
        ["z_dy", "tum"],
        ["Inzidenzort_BL", "tum"],
        ["icd10_3d", "tum"],
        ["Morphologie_Version", "tum"],
        ["TNM_Auflage_p", "tum"],
        ["z_t_p_1", "tum"],
        ["z_is_dco", "tum"],
        ["z_n_p_1", "tum"],
        ["z_m_p_1", "tum"],
    ]

    db_vars = (Tumor.set_alias("t")
               .project(*, left(Diagnose.ICD10_Code,3) as icd10_3d, left(Inzidenzort,2) as Inzidenzort_BL, z_dy, z_is_dco)
               .join(Patient.oBDS_RKIPatientId)
               .join(dim_lieferregister, "t.z_kkr::int = code::int" "inner")
               .join(dim_icd10_3d.set_alias("i"), "icd10_3d=i.code")
               .filter(filter if filter else "True")
               .aggregate(
                   f"{group_reg}, {agg_cols[idx][0]} as value, count({agg_counts[agg_cols[idx][1]}) as cnt"
               )

    # * optional dim applikation
    if idx==2:
        db_vars = (db_vars
                   .join(dim_tnm_uicc.set_alias("dim"), "value = dim.code", "left")
                   .project(f"{group_reg}, code_1 as value, cnt"))
    elif idx==3:
        db_vars = (db_vars
                   .join(dim_dsich_clin, "value = code", "left")
                   .project(f"{group_reg}, concat(code, ' - ', name) as value, cnt"))
    elif idx==6:
        db_vars = (db_vars
                   .join(dim_icd10_3d, "value = code", "left")
                   .project(f"{group_reg}, code_kid as value, cnt"))
    # elif idx==9:
    #     db_vars = (db_vars
    #                 .join(dim_tnm_t, "value = code", "left")
    #                 .project(f"{group_reg}, code_1 as value, cnt"))

    df = db_vars.to_df()
    if idx==4:
        df["value"] = df["value"].astype("Int64").astype(str)

    df = df.rename(columns={"value": agg_cols[idx][0]})
    if show:
        pls.plot_stacked_bars(df, swap=False, orientation='h', show_total=True, normalize=False, relative=True, height=1000)
    return df
```

UICC (p)



- **Filter: DJ = 2020-2023, DCO = N, ICD10 nur solide Tumoren** (solide Tumoren schliesst folgende Diagnosen aus: C44, C70-C72, C76-C97, alle D)
- nach den absoluten Werten ist auch die relative Verteilung gegeben unter Ausschluss der hohen Zahl an UICC missings
- die Variable wird in den meisten kkr selbst gebildet. Für GTDS Länder ist dafür ein Standard definiert

🔍 **NI:** "UICC-Stadium: In Tristan ist die Implementierung zur automatisierten Ermittlung des UICC-Stadiums ausstehend. Bis zur Umsetzung der Implementierung wird das KKN **keine gesonderte Berechnung** des UICC-Stadiums vornehmen, liefert aber die Werte, die gemeldet worden sind"

🔍 **HH:** "Komplett fehlende UICC-Stadien: Teilweise bei uns unter **weitere Klassifikationen** zu finden und erst ab 2023 in einem eigenen Feld. UICC nach TNM-8 ist noch nicht vollständig in unserer Datenbank berechnet."

```
_tu=show_vars(2, grouper_reg.KKR.value, show=False, filter=fil_dy_no_solid_no_dco)
_=pls.plot_stacked_bars(_tu, swap=False, orientation='h', show_total=False, relative=False, height=1000)
_=pls.plot_stacked_bars(_tu, swap=False, orientation='h', show_total=True, relative=True, height=1000, dropna=True)

# todo (DCN in klin. epi Fällen für GKR länder) pro DJ
```



Diagnosesicherung

- Filter: DJ = 2020-2023

🔔 NI: "Die Ausprägung DCO als Diagnosesicherung kommt im KKN-Datensatz nicht vor. Diese Information liegt bisher nur dem EKN vor und wird gegebenenfalls zur Anreicherung von Datenexporten fallspezifisch vom KKN beim EKN angefragt. Der Prozess zur automatisierten Übermittlung dieser Informationen vom EKN zum KKN ist in Planung"

🔔 ZfKD: "aufgrund der verschiedenartigen Handhabung von DCO in den übermittelten Daten ist die Filterung nach DCO mit erheblicher Unschärfe verbunden"

```
_ = show_vars(3, grouper_reg.KKR.value, show=True, filter=fil_dy)
```




Geschlecht

- Grundgesamtheit: Menge aller Patienten
- Filter: DJ = 2020-2023

💡 ZfKD: 'Angaben zu Geschlecht ungleich M oder W sind sehr selten, diese Fälle werden nicht gesondert verarbeitet'

```
_tu=show_vars(0, grouper_reg.KKR.value, show=True, filter=fil_dy)
_other = _tu[_tu["Geschlecht"].isin(["M", "W"])].groupby("Geschlecht")["cnt"].sum().to_dict()
print(f"Anzahl Ausprägungen < M oder W im Gesamtdatensatz: {_other}")
```



Anzahl Ausprägungen < M oder W im Gesamtdatensatz: {'D': 37, 'U': 212, 'X': 28}


Diagnosejahr

- Filter: Top 5 Diagnosejahre
- Legende ist absteigend sortiert nach Fallzahl im DJ, Restkategorie <other> ist aufgeführt

```
_tu = show_vars(4, grouper_reg.KKR.value, show=False)
print(
    f"Anzahl {str(dy_max+1)} Fälle: {_tu[_tu['z_dy'] = str(dy_max+1)].set_index('kk').to_dict()}"
)
_ = pls.plot_stacked_bars(
```

```
_tu,
swap=False,
orientation="h",
show_total=True,
normalize=False,
relative=True,
height=1000,
top_n_color=4,
sort_values_color=True,
show_other=True,
)
```

Anzahl 2024 Fälle: {'12-BB': 642, '13-MV': 2835, '09-BY': 2233, '06-HE': 844, '08-BW': 679, '15-ST': 1917, '11-BE': 509}



Inzidenzort vs Lieferregister

- **Filter:** keiner, Grundgesamtheit sind alle Fälle
 - **vertikal:** Inzidenzort (Zeile 00 bündelt alle Fälle mit ungültiger Ortsangabe). horizontal: Lieferregister
 - **Beispiel:** 03-NI liefert zu 100% Fälle aus dem Inzidenzort 03, 13-MV liefert 159 Fälle aus 03
- 🔗 ZfKD: "angestrebt ist eine "Diagonale", möglichst nur noch Fallübermittlungen aus dem eigenen Einzugsgebiet, was inzwischen schon besser erreicht ist. Mindestens 99% der Fälle stammen aus dem liefernden Register"

```
_tu = show_vars(5, grouper_reg.KKR.value, show=False).rename(columns={"Inzidenzort_BL": "ort"}).fillna(0)
_tu.loc[_tu["ort"]=="", "ort"]="00"
_tu.loc[(~_tu["ort"].astype(int) < 1) | (~_tu["ort"].astype(int) > 16), "ort"]="00"
tbl.show_num_df(_tu.pivot_table(index='ort', columns='kkv', values='cnt', fill_value=0, dropna=False), data_bar_axis="xy", total_axis="xy",
total_exclude=True, pct_axis="x")
```

kkv	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
ort																	
00	0	0	0	0	0	1 (0.0%)	0	0	4 (0.0%)	0	1 (0.0%)	36 (0.0%)	497 (0.5%)	0	0	0	539 (0.0%)
01	150,685 (100.0%)	0	0	0	0	0	0	0	0	0	0	7 (0.0%)	29 (0.0%)	1 (0.0%)	0	0	150,722 (4.7%)
02	0	55,559 (100.0%)	0	0	0	0	0	0	0	0	0	0	2 (0.0%)	4 (0.0%)	0	0	55,565 (1.7%)
03	0	0	216,710 (100.0%)	0	0	238 (0.1%)	0	0	0	0	1 (0.0%)	0	226 (0.2%)	3 (0.0%)	0	0	217,178 (6.7%)
04	0	0	0	25,182 (100.0%)	0	0	0	0	0	0	0	0	0	0	0	0	25,182 (0.8%)
05	0	0	0	0	805,679 (100.0%)	100 (0.1%)	0	0	0	0	0	1 (0.0%)	0	8 (0.0%)	0	0	805,788 (24.9%)
06	0	0	0	0	0	174,121 (99.7%)	0	0	1 (0.0%)	0	0	0	0	8 (0.0%)	78 (0.1%)	0	174,208 (5.4%)
07	0	0	0	0	0	3 (0.0%)	123,111 (100.0%)	0	1 (0.0%)	0	0	0	0	4 (0.0%)	0	0	123,119 (3.8%)
08	0	0	0	0	0	10 (0.0%)	0	362,189 (100.0%)	269 (0.1%)	0	0	0	6 (0.0%)	6 (0.0%)	0	0	362,480 (11.2%)
09	0	0	0	0	0	90 (0.1%)	0	0	431,537 (99.9%)	0	8 (0.0%)	15 (0.0%)	5 (0.0%)	25 (0.0%)	0	0	431,680 (13.3%)
10	0	0	0	0	0	0	0	0	0	48,061 (100.0%)	0	0	2 (0.0%)	0	0	0	48,063 (1.5%)


kk	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
ort																	
11	0	0	0	0	0	0	0	0	0	0	114_554 (99.7%)	4 (0.0%)	1 (0.0%)	4 (0.0%)	0	0	114_563 (3.5%)
12	0	0	0	0	0	0	0	0	0	0	345 (0.3%)	104_155 (99.9%)	375 (0.3%)	12 (0.0%)	0	0	104_887 (3.2%)
13	0	0	0	0	0	0	0	0	0	0	0	26 (0.0%)	107_984 (98.9%)	1 (0.0%)	0	0	108_011 (3.3%)
14	0	0	0	0	0	0	0	0	0	0	0	1 (0.0%)	2 (0.0%)	300_118 (100.0%)	0	0	300_121 (9.3%)
15	0	0	0	0	0	0	0	0	0	0	0	50 (0.0%)	12 (0.0%)	17 (0.0%)	126_114 (99.9%)	0	126_193 (3.9%)
16	0	0	0	0	0	1 (0.0%)	0	0	1 (0.0%)	0	1 (0.0%)	0	0	17 (0.0%)	0	92_037 (100.0%)	92_057 (2.8%)
Total	150_685 (100.0%)	55_559 (100.0%)	216_710 (100.0%)	25_182 (100.0%)	805_679 (100.0%)	174_564 (100.0%)	123_111 (100.0%)	362_189 (100.0%)	431_813 (100.0%)	48_061 (100.0%)	114_910 (100.0%)	104_295 (100.0%)	109_141 (100.0%)	300_228 (100.0%)	126_192 (100.0%)	92_037 (100.0%)	3_240_356 (100.0%)

ICD10 Gruppen

- die verwendete ICD10 Skala entspricht der Darstellung aus "Krebs in Deutschland"

⚠ NI: "Für nicht-melanozytäre Hautkrebsarten bestimmter Histologien sowie fortgeschrittene Plattenepithelkarzinome gilt ab dem 20. September 2023 eine geänderte Meldepflicht. Erst seit diesem Zeitpunkt sind die prognostisch ungünstigen Hauttumore (C44) an das KKN zu melden und kommen daher im gelieferten Datensatz bisher nicht vor. In den nächsten Lieferungen werden diese Daten enthalten sein"


```
_ = show_vars(6, grouper_reg.KKR.value, show=True, filter=fil_dy)
```



Verstorben

- Filter: DJ = 2020-2023, DCO = N, ICD10 != C44


```
_ = show_vars(1, grouper_reg.KKR.value, show=True, filter=f"z_dy > 2019 and z_dy ≤ {dy_max} and icd10_3d ≠ 'C44' and not z_is_dco")
```



TNM-T (p)

- Filter: DJ = 2020-2023, DCO = N, ICD10 nur solide Tumoren (solide Tumoren schliesst folgende Diagnosen aus: C44, C70-C72, C76-C97, alle D)


```
_show_vars(9, grouper_reg.KKR.value, show=True, filter=fil_dy_no_solid_no_dco)
```



TNM-N (p)

- Filter: DJ = 2020-2023, DCO = N, ICD10 nur solide Tumoren (solide Tumoren schliesst folgende Diagnosen aus: C44, C70-C72, C76-C97, alle D)


```
_show_vars(11, grouper_reg.KKR.value, show=True, filter=fil_dy_no_solid_no_dco)
```



TNM-M (p)

- Filter: DJ = 2020-2023, DCO = N, ICD10 nur solide Tumoren
- Zfkd: "pM0 und pMX sind nach TNM Manual keine anwendbaren Kodierungen"


```
_ = show_vars(12, grouper_reg.KKR.value, show=True, filter=fil_dy_no_solid_no_dco)
```



TNM-Auflage (p)

- Filter: DJ = 2020-2023

```
_ = show_vars(8, grouper_reg.KKR.value, show=True, filter=fil_dy)
```




Todesursachen (TU)

nach ICD10 Einstellern

- gezählt sind die ersten Stellen aller TU Codes ohne jeglichen Filter

```
db_tu = Todesursache.project("*, upper(substr(Code, 1,1)) as tu_1d")
_ = pls.plot_bars(db_tu.aggregate("tu_1d, count(*) as cnt").to_df(), orientation='v', sort_values=True, height=500,)
```

[cnt] by [tu_1d], n=35 (957_281)



nach Sterbejahr und Todesursachen

- gezählt werden **Personen**
- Filter: SJ= 2020-2023, Verstorben= J**
- tu_type** Art der TU pro Patient
 - <NA> keine Todesursache
 - C Todesursache Cxx
 - <other> andere Todesursache

💡 ZfKD: "03-NI und 06-HE übermitteln deutlich weniger Todesursachen als in den epi Daten, für 07-RP ist der Anteil in beiden Datenräumen gering. Für 15-ST sind auffällig wenige Todesfälle in 2023 übermittelt."

```
# # * get list of all patient and their first TU
_tu = (Patient.set_alias("p")
      .join(Todesursache, "oBDS_RKIPatientId", "inner")
      .aggregate("p.oBDS_RKIPatientId, min(Code) as code")
      )
# _tu
```

```
db_tu=(
  Patient
  .join(_tu, "oBDS_RKIPatientId", "left")
  .join(Tumor, "oBDS_RKIPatientId", "left")
  .filter(f"year(DatumVitalStatus::date) between 2020 and {dy_max} and Verstorben='J'")
  .project("""--sql
    --z_dy
    year(DatumVitalStatus::date) as SJ
    --,left(code,3) as tu
    ,case
      when left(code,1)='C' then 'C'
```

```

        when left(code,1) <> 'C' then '<other>'
        else null end as tu_type
        , z_kkr_label
    """
)
df_tu = db_tu.to_df()
# 974_056

```

```

_ = pls.plot_facet_stacked_bars(
    df_tu,
    subplots_per_row=4,
    top_n_color=5,
    sort_values_color=True,
    show_other=False,
    relative=True,
    annotations=True
)

```

[SJ] TOP 5 [tu_type] [z_kkr_label] , n=764_606 (764_606)



nach hat_todesursache bei Nicht-Verstorbenen

- gezählt werden **Personen**
- Filter: **Verstorben = N**

💡 HH: "Da haben wir jetzt gesehen, dass es an dem Überhang-Konstrukt liegt. Da handelt es sich um Patienten, die im Datenlieferungszeitraum <31.12.2022 noch gelebt haben, aber dann innerhalb des Zeitraums zur Erstellung des Datensatzes (01.02.2024) verstorben sind. Da passen wir unseren Datenexport noch einmal an."

```

_pat = Patient.filter("Verstorben='N'").project("oBDS_RKIPatientId")
_df = (Todesursache

```

```
.join(_pat, "oBDS_RKIPatientId")
.aggregate("z_kkr, count(distinct oBDS_RKIPatientId) as has_tu")
.join(dim_lieferregister, "z_kkr::int=code::int", "right")
.project("kkr, has_tu")
.order("kkr")
.to_df().set_index("kkr").fillna(0)
.T
)
tbl.show_num_df(_df, total_axis="", heatmap_axis="x")
```

kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
has_tu	0	980	0	0	0	0	0	0	1	8	1	5	472	0	0	3	0

nach ICD10 Dreistellern (TOP 5)

- Grundgesamtheit: alle Todesursachen, kein Filter

💡 ZfKD: 'enthalten sind in einigen KKR auch C79 (Metastasen), welche in offizieller Todesursachen-Statistik nicht kodiert sind'


```
_tu = (
    Todesursache.aggregate("z_kkr, left(Code,3) as tu_3d, count(*) as cnt")
    .join(dim_lieferregister, "z_kkr::int = code::int")
    .project("tu_3d,kkr, cnt")
    .to_df()
    # .pivot_table(index='tu_3d', columns='kkr', values='cnt', fill_value=0, dropna=False)
)
tbl.show_num_df(_df, data_bar_axis="xy", total_axis="xy", total_exclude=True, pct_axis="x",)
tbl.pivot_df(_tu, top_n_index=5, data_bar_axis="xy", pct_axis="", swap=False, heatmap_axis="", total_axis="y")
```

kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
tu_3d																	
C18	974	794	15	259	8.683	121	257	4.522	5.709	520	1.862	1.765	924	3.038	746	363	30.552
C25	1.740	1.209	29	423	13.927	196	353	7.329	7.380	744	3.207	2.736	1.566	4.300	966	584	46.689
C34	4.533	3.335	85	1.299	36.471	776	935	14.222	14.437	2.068	8.296	6.121	3.621	7.126	2.047	1.246	106.618
C78	0	0	0	0	190	2.338	1.462	0	6.731	0	4.476	4.035	1.948	6.013	1.373	921	29.487
C79	0	0	0	0	166	2.703	1.984	0	19.442	0	3.804	2.294	1.184	3.536	715	405	36.233

nach IsGrundleiden

- Grundgesamtheit: alle Todesursachen

```
_tu = (
    Todesursache.aggregate(
        "z_kkr, cast(IsGrundleiden as bool) as is_grundleiden, count(*) as cnt"
    )
    .join(dim_lieferregister, "z_kkr::int = code::int")
    .project("kkr, is_grundleiden, cnt")
    .to_df()
)
_=pls.plot_stacked_bars(_tu, orientation="h", height=800, relative=True, show_total=True)
```




OP

nach ICD10

- Grundgesamtheit: alle OP Meldungen

```
_op = (OP
    .join(Tumor
        .set_alias("t")
        .project("*, left(Diagnose_ICD10_Code,3) as icd10_3d",
            "z_tum_id")
        .filter(fil_dy)
        .aggregate("icd10_3d, t.z_kkr, count(*) as cnt")
    )
    .join(dim_lieferregister, "z_kkr::int = code::int")
    .project("kkr, icd10_3d, cnt")
    .to_df()
)
_=pls.plot_stacked_bars(_op, orientation="h", height=800, top_n_color=10, relative=True, sort_values_color=True, show_other=True, show_total=True)
```

[kkr] by TOP10 [icd10_3d], n=1_779 (1_614_057)




nach Intention

- Grundgesamtheit: alle OP Meldungen

```
_op = (OP
    .join(Tumor.set_alias("t"), "z_tum_id")
    .aggregate("Intention", t.z_kkr_label, count(*) as cnt")
    .join(dim_op_intention.set_alias("i"), "Intention=i.code")
    .project("z_kkr_label,concat(i.code, ' - ', i.name) as label, cnt")
    .to_df())
_ppls.plot_stacked_bars(_op, orientation="h", height=800, top_n_color=0, relative=True, show_total=True)
```

[z_kkr_label] by [label], n=102 (1_654_671)




OPS

nach OPS ICD Kapitel (Top 10)

- Grundgesamtheit: alle OPS Codes

🔔 ZfKD: "lediglich 02-HH und 05-NW übermitteln ausschliesslich Kapitel 5. Der Anteil von Meldungen <- Kapitel 5 sind wahrscheinlich diagnostische Massnahmen oder nicht-operative Therapien. Vorschlag: nur noch Kapitel 5 übermitteln"

```
_ops = (OPS
    # .join(Tumor.set_alias("t"), "oBDS_RKIPatientTumorId")
    .aggregate("Left(Code,1) as code_id, z_kkr, count(*) as cnt")
    .join(dim_lieferregister, "z_kkr::int=code::int")
    .project("kkr, code_id, cnt")
    .to_df())
_ppls.plot_stacked_bars(_ops, orientation="h", height=800, top_n_color=10, relative=True, sort_values_color=False, show_total=True)
```



nach OPS Einzelcodes (Top 5)

- Grundgesamtheit: alle OPS Codes

```
_ops = (OPS.set_alias("o")
        .aggregate("Code, z_kkr, count(*) as cnt")
        .join(dim_lieferregister.set_alias("l"), "z_kkr::int=l.code::int")
        .project("o.Code,kkr, cnt")
        .to_df()
        )
# _ops
tbl.pivot_df(_ops, top_n_index=5, data_bar_axis="y", pct_axis="", heatmap_axis="", total_axis="y")
# todo auflösen
```

kkrr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
Code																	
5-401.11	5_918	3_813	15_148	1_567	26_109	10_773	7_035	20_972	11_089	1_802	6_533	4_868	3_709	8_246	4_534	3_710	135_826
5-573.40	3_533	2_481	4_993	658	27_975	3_653	4_640	10_415	7_042	750	4_815	4_751	2_709	8_896	4_184	2_771	94_266
5-870.a1	2_540	1_565	7_058	421	12_354	6_018	4_259	9_957	5_532	730	3_600	1_670	1_381	3_660	1_768	2_527	65_040
5-870.a2	2_217	2_467	4_447	236	10_668	3_894	2_255	9_726	5_972	901	2_858	1_903	1_155	1_890	1_428	393	52_410
5-987.0	1_983	980	5_718	391	25_080	4_778	2_841	13_487	11_218	758	3_753	2_804	1_063	4_136	2_419	1_352	82_761


SYST

nach Stellung_OP

- Grundgesamtheit: alle SYST Elemente

💡 Zfkd: "einige KKR übermitteln de facto keine OP Stellung"

```
_syst = (SYST
        .join(Tumor.set_alias("t"), "z_tum_id")
        .aggregate("Stellung_OP, t.z_kkr_label, count(*) as cnt")
        .join(dim_syst_op_stellung.set_alias("s"), "Stellung_OP=s.code")
        .project("z_kkr_label,concat(s.code, ' - ', s.name) as label, cnt")
        .to_df()
        )
_pis.plot_stacked_bars(_syst, orientation="h", height=800, top_n_color=0, relative=True, show_total=True)
```



Missings / Unbekannt in den Daten

- es sind folgende Schwellwerte angezeigt:
 - 0 bis <5%
 - 5 bis <100%
 - bei 100%
- Filter: DJ 2020-2023** Weitere Filter sind extra aufgeführt
- dargestellt sind Variablen aus dem Schema in folgender Notation: **[Elementknoten]Variablenname**
- die grau melierte **0** kennzeichnet einen leeren Wert (=keine missings), 0% entsteht durch Rundung von kleinen Werten

```
#
# * available filter cols: ['kkr', 'table', 'column', 'tablecolumn', 'Diagnose_ICD10_Code_DREI', 'DC0', 'DJ_clipped', 'sel1_relevant', 'sel2_organ',
'sel3_TNM', 'sel4_datum', 'sel5_pflicht', 'sel6_mamma', 'sel7_prostata', 'sel8_prio']

def show_missings(kpi_type: str, filter: str = "", group_table: str = grouper_table.TABLECOL.value):

    if filter and group_table == grouper_table.TABLES.value:
        print("❌ no filter allowed on tables agg level")
        return

    if not filter:
        filter="True"

    # * start
    db_tree = _treecompletion

    # * only join if column is involved
    if group_table == grouper_table.TABLECOL.value:
        db_tree = (db_tree
                    .set_alias("t2")
                    .join(dim_tree.set_alias("tr"), f"t2.{group_table}=tr.{group_table}", "inner")
                    .project(" exclude (t2.tables, t2.tablecolumn)")
        )

    # * then go on, create df
    df_tree = (db_tree.set_alias("t")
               .join(dim_lieferregister.set_alias("l"), "t.kkr::int=l.code::int", "inner")
               .join(dim_icd10_3d.set_alias("i"), "icd10_3d = i.code", "left")
               # * we want the enriched kkr str
               .project(" replace (l.kkr as kkr)")
               # * to use filter, dim_tree must have been joint
               .filter(filter)
               .aggregate(f"""--sql
kkr, {group_table} --, Diagnose_ICD10_Code_DREI, DC0, DJ_clipped
sum(allHasValues) as allHasValues, sum(sumIsMissing) as sumIsMissing, sum(sumIsUnknown) as sumIsUnknown, sum(sumRelatedTumors) as
sumRelatedTumors
"""))
    .project(f"""--sql
kkr, {group_table} --, Diagnose_ICD10_Code_DREI, DC0, DJ_clipped
,case when allHasValues = 0 then 1 else case when sumRelatedTumors = 0 then 0 else sumIsMissing / sumRelatedTumors end end as
kpi_missing
""", case when sumRelatedTumors = 0 then 0 else sumIsUnknown / sumRelatedTumors end as kpi_unknown
    )
    .to_df()
    # .pivot(index=group_table, columns="kkr", values=kpi_type)
    )

    # * create the table for Totals
    df_tree_total = (db_tree.set_alias("t")
                     .join(dim_icd10_3d.set_alias("i"), "icd10_3d = i.code", "left")
                     # * to use filter, dim_tree must have been joint
                     .filter(filter)
                     .aggregate(f"""--sql
{group_table} --, Diagnose_ICD10_Code_DREI, DC0, DJ_clipped
sum(allHasValues) as allHasValues, sum(sumIsMissing) as sumIsMissing, sum(sumIsUnknown) as sumIsUnknown, sum(sumRelatedTumors) as
sumRelatedTumors
"""))
    .project(f"""--sql
'Total' as kkr, {group_table} --, Diagnose_ICD10_Code_DREI, DC0, DJ_clipped
,case when allHasValues = 0 then 1 else case when sumRelatedTumors = 0 then 0 else sumIsMissing / sumRelatedTumors end end as
kpi_missing
""", case when sumRelatedTumors = 0 then 0 else sumIsUnknown / sumRelatedTumors end as kpi_unknown
    )
    .to_df()
    # .pivot(index=group_table, columns="kkr", values=kpi_type)
    )

    # * concat both tables
    df_all = df_tree
    # ! dt_tree_total is still experimental
    # df_all = pd.concat([df_tree, df_tree_total], axis=0)
    # display(df_all)
    df_all = df_all.pivot(index=group_table, columns="kkr", values=kpi_type)

    out = tbl.show_num_df(df_all,
                          data_bar_axis="xy",
                          total_axis="",
                          pct_axis="",
                          precision=1,
                          kpi_mode="rag_abs",
                          # * red threshold: 100% missings | 40% unknown
                          kpi_rag_list=[0.05, 1] if kpi_type == kpi.MISSINGS.value else [0.05, 0.35],
                          show_as_pct=True,
    )
    display(out)
```

Missings für verpflichtende Variablen in Tumor Element

- kein Filter
- Pflichtangaben aus anderen Elementknoten (z.B. Datum aus dem OP Knoten) sind nicht aufgeführt, da diese selbst optional sind
- ganz überwiegend sind die Angaben vollständig, die wenigen Ausnahmen werden allerdings Stand heute nicht korrigiert

ZfKD: "Die absoluten Fallzahlen für fehlende ICD10 oder Inzidenzort sind sehr gering, verursachen jedoch in Analysen einige Artefakte, wenn sie in Filtern nicht korrekt adressiert werden"

```
show_missings(
    kpi.MISSINGS.value,
    filter=f"sel5_pflicht",
    group_table=grouper_table.TABLECOL.value,
)
```

kk	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumn																
[Patient]DatumVitalStatus	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Patient]Geburtsdatum	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Patient]Geschlecht	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Patient]Verstorben	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]DCN	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]Diagnose_ICD10_Code	0	0	0	0	0	0	0	0	0	0	0	0.0%	0.4%	0	0	0.2%
[Tumor]Diagnosedatum	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]Diagnosesicherung	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]Inzidenzort	0	0	0	0	0	0	0	0	0	0	0	0	0.9%	0	0	0
[Tumor]Seitenlokalisation	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

Missings für Therapieangaben

- Filter: DJ 2020-2023, DCO = N, ICD10 != C44
- Rechenbeispiel für [Bestrahlung]Anzahl_Tage_Diagnose_ST in 01-SH (Zahlen sind veraltet, aber Prinzip bleibt gleich):
 - 5363 Bestrahlungen sind in den Daten unter Beachtung des Filters (DCO/DJ/ICD10) für den zugeordneten Tumor
 - davon enthalten 302 ein leeres Feld Anzahl_Tage_Diagnose_ST -> ~ 6%

🔍 ZfKD: "Es gibt deutliche Unterschiede in der Nutzbarkeit von Therapieangaben. So weist etwa Anzahl_Tage_Diagnose_OP fast keine missings auf, Anzahl_Tage_SYST_Dauer jedoch (flächendeckend) sehr viele."

```
show_missings(
  kpi.MISSINGS.value,
  filter=f"{fil_pd_dco_dy} and {fil_pd_c44} and tables in ('OP','ST','Bestrahlung','SYST') and tablecolumn not ilike '%genauigkeit'",
  group_table=grouper_table.TABLECOL.value,
)
```

kk	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumn																
[Bestrahlung]Anzahl_Tage_Diagnose_ST	5.3%	0	6.7%	6.1%	0.4%	0	10.2%	0.1%	0.1%	5.4%	0.0%	0.0%	0.0%	0	0.0%	0.0%
[Bestrahlung]Anzahl_Tage_ST_Dauer	100.0%	2.2%	100.0%	100.0%	8.6%	3.9%	5.8%	0	3.8%	100.0%	1.4%	1.3%	1.9%	0.4%	1.3%	1.4%
[Bestrahlung]Datum_Beginn_Bestrahlung	0	0	0	0	0	0	0	0	0	0	0.0%	0.0%	0.0%	0	0	0.0%
[OP]Anzahl_Tage_Diagnose_OP	1.5%	0	2.8%	2.9%	3.0%	0	4.8%	2.2%	0.0%	2.7%	0	0	0	0	0	0.0%
[OP]Datum_OP	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[OP]Intention	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[OP]Lokale_Beurteilung_Residualstatus	100.0%	4.2%	100.0%	100.0%	8.7%	10.3%	1.8%	0.0%	14.7%	100.0%	10.8%	11.1%	5.1%	7.0%	15.4%	16.4%
[ST]Intention	0.0%	0	0.4%	0.0%	0.0%	0.1%	0	0	3.5%	0	0.2%	0.1%	0.0%	0.0%	0.0%	1.1%
[ST]Stellung_OP	100.0%	0.0%	100.0%	100.0%	0	0.7%	0.3%	0	3.9%	100.0%	0	0.0%	0.1%	0.0%	0.0%	1.6%
[SYST]Anzahl_Tage_Diagnose_SYST	6.4%	0	11.1%	12.3%	1.1%	0	16.8%	0.4%	0.1%	13.3%	0.0%	0.0%	0.1%	0	0.0%	0.0%
[SYST]Anzahl_Tage_SYST_Dauer	100.0%	31.3%	100.0%	100.0%	43.1%	35.7%	40.8%	0	44.7%	100.0%	32.2%	40.1%	37.0%	33.3%	40.5%	37.3%
[SYST]Datum_Beginn_SYST	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[SYST]Intention	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[SYST]Stellung_OP	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[SYST]Therapieart	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

Missings für Tumorstadien

- Filter: DJ 2020-2023, DCO = N, ICD10 nur solide Tumoren

🔍 ZfKD: "0% missings ist bei diagnoseabhängigen Angaben wie den Tumorstadien nicht zu erreichen (05-NW hat die Auflage als Konstante im Datensatz hinterlegt). Hier kann nur der relative Vergleich als Maßstab dienen."

```
show_missings(
  kpi.MISSINGS.value,
  filter=f"{fil_pd_dco_dy} and sel3_TNM and is_solid",
  group_table=grouper_table.TABLECOL.value,
)
```

kk	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumn																
[Tumor]M_c	39.9%	24.3%	55.4%	32.2%	28.4%	55.1%	71.5%	45.5%	56.2%	31.4%	36.3%	40.1%	35.0%	34.2%	44.2%	44.6%
[Tumor]M_p	44.6%	93.3%	54.3%	46.8%	92.5%	56.8%	55.6%	50.9%	60.7%	90.9%	48.2%	49.2%	45.6%	40.8%	46.1%	42.1%
[Tumor]N_c	39.2%	36.9%	53.4%	32.2%	40.5%	53.3%	72.2%	49.3%	54.5%	41.7%	34.9%	39.1%	34.7%	34.2%	45.2%	44.3%

kk	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumn																
[Tumor]N_p	38.0% 	61.3% 	47.0% 	44.5% 	59.3% 	46.4% 	53.0% 	64.9% 	46.7% 	55.4% 	45.5% 	45.7% 	42.5% 	40.6% 	45.9% 	41.6%
[Tumor]TNM_Auflage_c	38.1% 	19.7% 	51.4% 	30.1% 	0 	48.5% 	63.4% 	45.5% 	49.9% 	25.8% 	32.2% 	33.9% 	31.8% 	33.9% 	42.1% 	43.1%
[Tumor]TNM_Auflage_p	35.7% 	38.8% 	41.0% 	43.0% 	0 	40.8% 	49.8% 	50.8% 	39.4% 	32.6% 	42.5% 	42.3% 	39.0% 	40.3% 	44.1% 	40.7%
[Tumor]T_c	39.0% 	45.7% 	50.8% 	31.2% 	47.0% 	48.5% 	65.3% 	45.5% 	49.9% 	47.2% 	32.2% 	33.9% 	31.7% 	33.9% 	42.0% 	43.1%
[Tumor]T_p	35.9% 	43.7% 	41.0% 	42.9% 	45.2% 	40.8% 	49.8% 	50.8% 	39.4% 	41.2% 	42.5% 	42.3% 	39.0% 	40.3% 	44.1% 	40.7%
[Tumor]UICC_Stadium_c	49.6% 	100.0% 	100.0% 	38.0% 	100.0% 	59.4% 	76.8% 	53.8% 	60.5% 	87.6% 	45.3% 	50.4% 	40.7% 	36.8% 	46.6% 	50.2%
[Tumor]UICC_Stadium_p	50.4% 	100.0% 	100.0% 	52.1% 	100.0% 	61.6% 	69.5% 	72.2% 	63.1% 	90.5% 	55.2% 	55.9% 	49.2% 	43.1% 	47.6% 	45.8%
[Tumor]c_p_u_Praefix_T_c	47.6% 	45.7% 	51.5% 	31.3% 	47.0% 	49.4% 	72.7% 	45.5% 	50.1% 	47.2% 	35.5% 	36.8% 	34.2% 	43.1% 	43.2% 	71.2%
[Tumor]c_p_u_Praefix_T_p	35.9% 	43.7% 	41.2% 	43.0% 	45.2% 	40.8% 	49.8% 	50.8% 	39.4% 	41.2% 	42.5% 	42.3% 	39.0% 	40.3% 	44.1% 	40.7%

Missings für organspezifische Variablen (Mamma)

- Filter: DJ 2020-2023, DCO = N, ICD10 = C50
- die Prozentwerte sind bei allen Darstellungen gerundet, "100%" bei einer gelben Ampel kann interpretiert werden als knapp unter 100%

HH "Fehlende Modul-Angaben (C50, C61) 2021. Sind bei uns noch nicht im xml enthalten."

```
show_missings(
  kpi.MISSINGS.value,
  filter=f"{fil_pd_dco_dy} and sel6_mamma and icd10_3d='C50'",
  group_table=grouper_table.TABLECOL.value,
)
```

kk	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumn																
[Tumor]Her2neuStatus	16.9% 	100.0% 	6.2% 	1.0% 	40.9% 	18.0% 	35.7% 	11.9% 	13.1% 	5.7% 	0.6% 	0.9% 	4.0% 	0.9% 	8.5% 	9.4%
[Tumor]HormonrezeptorStatus_Oestrogen	14.3% 	100.0% 	6.2% 	1.0% 	40.1% 	17.6% 	35.8% 	11.8% 	29.5% 	5.4% 	7.9% 	8.2% 	18.0% 	2.9% 	11.2% 	5.6%
[Tumor]HormonrezeptorStatus_Progesteron	14.4% 	100.0% 	6.2% 	1.0% 	40.0% 	17.3% 	35.8% 	16.1% 	29.5% 	5.2% 	8.0% 	8.3% 	18.0% 	2.9% 	11.3% 	5.6%
[Tumor]Praetherapeutischer_Menopausenstatus	21.1% 	100.0% 	39.0% 	6.3% 	34.4% 	39.5% 	43.2% 	29.7% 	43.0% 	27.1% 	24.9% 	34.3% 	24.0% 	9.3% 	34.5% 	42.4%
[Tumor]TumorgroesseDCIS	70.6% 	100.0% 	67.8% 	36.6% 	74.5% 	80.9% 	73.6% 	53.1% 	99.1% 	68.4% 	99.9% 	99.8% 	99.9% 	100.0% 	97.6% 	100.0%
[Tumor]TumorgroesseInvasiv	36.6% 	100.0% 	32.1% 	22.3% 	51.9% 	54.6% 	49.7% 	31.7% 	74.5% 	26.6% 	39.3% 	40.4% 	50.4% 	24.5% 	61.8% 	45.6%

Missings für organspezifische Variablen (Prostata)

- Filter: DJ 2020-2023, DCO = N, ICD10 = C61

ZfKD "Auch innerhalb eines KKR gibt es deutliche Varianzen zwischen Variablen des organspezifischen Moduls, z.B. in 11-16"

```
show_missings(
  kpi.MISSINGS.value,
  filter=f"{fil_pd_dco_dy} and sel7_prostata and icd10_3d='C61'",
  group_table=grouper_table.TABLECOL.value,
)
```

kk	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumn																
[Tumor]AnlassGleasonScore	20.5% 	100.0% 	10.4% 	7.7% 	100.0% 	65.3% 	56.4% 	13.9% 	54.7% 	8.2% 	46.0% 	56.4% 	40.8% 	39.2% 	74.7% 	87.8%
[Tumor]DatumPSA	42.2% 	100.0% 	39.6% 	36.5% 	100.0% 	45.6% 	63.9% 	95.5% 	44.0% 	27.4% 	23.1% 	21.5% 	19.9% 	13.3% 	28.9% 	17.8%
[Tumor]PSA	41.9% 	100.0% 	39.0% 	34.2% 	100.0% 	45.6% 	56.1% 	34.0% 	44.0% 	23.1% 	23.1% 	21.5% 	19.9% 	13.3% 	28.9% 	17.8%
[Tumor]ScoreErgebnis	18.5% 	100.0% 	8.5% 	7.7% 	100.0% 	20.7% 	52.6% 	10.5% 	22.0% 	4.1% 	9.5% 	8.6% 	12.3% 	4.2% 	8.1% 	9.4%

Missings für organspezifische Variablen (Darm)

- Filter: DJ 2020-2023, DCO = N, ICD10 = C18-C20

```
show_missings(
  kpi.MISSINGS.value,
  filter=f"{fil_pd_dco_dy} and sel9_darm and icd10_3d in ('C18','C19','C20')",
  group_table=grouper_table.TABLECOL.value,
)
```

kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumnn																
[Tumor]RASMutation	57.5%	100.0%	64.6%	43.8%	74.3%	71.2%	84.1%	64.7%	83.1%	78.2%	64.6%	71.5%	64.0%	86.8%	94.8%	79.5%
[Tumor]RektumAbstandAnokutanlinie	86.4%	100.0%	88.7%	87.0%	84.1%	80.2%	88.4%	82.8%	87.1%	83.2%	90.5%	84.2%	80.8%	77.6%	95.9%	92.3%

Missings für organspezifische Variablen (Melanom)

- Filter: DJ 2020-2023, DCO = N, ICD10 = C43

```
show_missings(  
  kpi.MISSINGS.value,  
  filter=f"{fil_pd_dco_dy} and sel10_melanom and icd10_3d in ('C43')",  
  group_table=groupier_table.TABLECOL.value,  
)
```

kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumnn																
[Tumor]LDH	98.4%	100.0%	96.3%	87.0%	100.0%	100.0%	97.7%	91.9%	100.0%	97.3%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%
[Tumor]Tumordicke	56.5%	100.0%	47.3%	21.2%	100.0%	100.0%	78.5%	17.1%	100.0%	46.0%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%
[Tumor]Ulzeration	62.7%	100.0%	64.2%	16.9%	100.0%	100.0%	82.3%	42.2%	100.0%	61.5%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%

Missings für Prio Variablen

- Filter: DJ 2020-2023, DCO = N, ICD10 != C44
- diese Variablen sind wesentlich für die Darstellung der Datenqualität ggü. Antragstellenden

```
show_missings(  
  kpi.MISSINGS.value,  
  filter=f"{fil_pd_dco_dy} and {fil_pd_c44} and sel8_prio",  
  group_table=groupier_table.TABLECOL.value,  
)
```

kk_r	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumnn																
[Applikationsart]CodeVersion2014	nan%	46.7%	nan%	nan%	100.0%	10.7%	nan%	24.9%	8.5%	nan%	16.9%	11.8%	0.4%	34.9%	18.7%	27.4%
[Applikationsart]CodeVersion2021	nan%	53.3%	nan%	nan%	0	89.4%	nan%	75.9%	93.3%	nan%	83.5%	88.4%	99.7%	65.3%	81.3%	73.0%
[Applikationsart]Seite_Zielgebiet	nan%	0.0%	nan%	nan%	0	0.0%	nan%	0.9%	0.9%	nan%	0.0%	0.0%	0.0%	0.2%	0.0%	0.3%
[Diagnose>WeitereKlassifikation]Name	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Diagnose>WeitereKlassifikation]Stadium	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Folgeereignis]Datum_Folgeereignis	nan%	0	nan%	nan%	0	0	0	0	0	nan%	0	0	0	0	0	0
[Folgeereignis]Gesamtbeurteilung_Tumorstatus	nan%	0	nan%	nan%	0	0	0	0	0	nan%	0	0	0	0	0	0
[Folgeereignis]Verlauf_Lokaler_Tumorstatus	nan%	61.2%	nan%	nan%	24.0%	26.1%	0.3%	0	37.9%	nan%	25.9%	26.8%	28.6%	28.7%	18.3%	21.5%
[Folgeereignis]Verlauf_Tumorstatus_Fernmetastasen	nan%	61.3%	nan%	nan%	25.2%	28.2%	0.4%	0	39.6%	nan%	24.1%	25.4%	31.0%	27.5%	17.0%	22.1%
[Folgeereignis]Verlauf_Tumorstatus_Lymphknoten	nan%	61.5%	nan%	nan%	26.0%	31.9%	0.4%	0	44.1%	nan%	31.0%	32.6%	32.7%	33.6%	20.5%	27.1%
[Folgeereignis_Fernmetastase]Lokalisation	nan%	0	nan%	nan%	0	0	0	0	0	nan%	0	0	0	0	0	0
[Folgeereignis>WeitereKlassifikation]Name	nan%	nan%	nan%	nan%	0	0	nan%	0	0	nan%	0	0	0	0	0	0
[Folgeereignis>WeitereKlassifikation]Stadium	nan%	nan%	nan%	nan%	0	0	nan%	0	0	nan%	0	0	0	0	0	0
[OPS]Code	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[OP]Anzahl_Tage_Diagnose_OP	1.5%	0	2.8%	2.9%	3.0%	0	4.8%	2.2%	0.0%	2.7%	0	0	0	0	0	0.0%
[OP]Lokale_Beurteilung_Residualstatus	100.0%	4.2%	100.0%	100.0%	8.7%	10.3%	1.8%	0.0%	14.7%	100.0%	10.8%	11.1%	5.1%	7.0%	15.4%	16.4%
[Protokoll]Bezeichnung	nan%	0	nan%	nan%	0	0	nan%	nan%	0	nan%	0	0	0	0	0	0
[Protokoll]Protokoll_TypProtokollschluessel_Code	nan%	100.0%	nan%	nan%	100.0%	100.0%	nan%	nan%	100.0%	nan%	100.0%	100.0%	100.0%	100.0%	100.0%	100.0%
[ST]Stellung_OP	100.0%	0.0%	100.0%	100.0%	0	0.7%	0.3%	0	3.9%	100.0%	0	0.0%	0.1%	0.0%	0.0%	1.6%
[SYST]Stellung_OP	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[SYST]Therapieart	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Substanz]Bezeichnung	nan%	0	nan%	nan%	0	86.0%	nan%	0	43.0%	nan%	91.4%	91.7%	0.1%	85.6%	81.4%	59.0%

kkkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumn																
[Substanz]SYST_TypSubstanzATC_Code	nan%	100.0%	nan%	nan%	100.0%	14.0%	nan%	100.0%	57.0%	nan%	8.6%	8.3%	100.0%	14.4%	18.6%	41.0%

Unbekannt für verpflichtende Variablen

- kein Filter
- die Darstellungen sind vorläufig, da die Definitionen für unbekannte Ausprägungen noch nicht ausgereift sind
- einige gewertet Unbekannt-Kodierungen aus der Auflistung
 - Diagnosesicherung = 9
 - Seitenlokalisation = U
 - Inzidenzort ist bislang nicht berücksichtigt

```
show_missings(  
  kpi.UNKNOWN.value,  
  filter=f"sel5_pflcht",  
  group_table=groupier_table.TABLECOL.value,  
)
```

kkkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
tablecolumn																
[Patient]DatumVitalStatus	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Patient]Geburtsdatum	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Patient]Geschlecht	0.0%	0.0%	0.0%	0.0%	0.0%	0	0.0%	0.0%	0.0%	0.0%	0.0%	0	0.0%	0	0	0.0%
[Patient]Verstorben	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]DCN	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]Diagnose_ICD10_Code	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]Diagnosedatum	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]Diagnosesicherung	4.9%	6.2%	8.3%	16.0%	5.8%	2.3%	11.4%	10.1%	1.7%	21.4%	1.2%	1.6%	1.8%	0.5%	1.2%	1.4%
[Tumor]Inzidenzort	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
[Tumor]Seitenlokalisation	5.8%	2.0%	2.0%	5.1%	18.8%	2.4%	1.4%	6.7%	5.0%	7.0%	2.3%	4.1%	0.7%	1.7%	5.6%	4.0%


Verteilung Monat von DatumVitalStatus

- Filter: alle Patienten mit Verstorben=N, DJ und SJ 2020-2023

⚠ HH: "Das liegt an unserer Darstellung des Vitalstatus-Datum. Nach Abschluss der DC-Recherche, die nach Abschluss des 'Todesjahres' durchgeführt wird, wird bei allen Patienten bei denen wir keine weiteren Meldungen bzw Informationen zum Vitalstatus bekommen haben der 31.12. des abgeschlossenen 'Todesjahres' gesetzt. In diesem Fall ist dies das aktuelle Jahr - 2 -> 31.12.2022, da die DC-Recherche zum Zeitpunkt der Datenlieferung noch nicht abgeschlossen war. Wenn jetzt ein Patient die letzte Meldung mit einem Leistungsdatum in 2019 hatte, wir aber keine weiteren Informationen bekommen haben, gehen wir also nach Abschluss der Recherche davon aus, dass der Patient am 31.12.2022 noch gelebt hat. Dadurch 'verbessert' sich tatsächlich der Vitalstatus in unseren Daten, ansonsten wäre dieser nämlich irgendwann in 2019."

⚠ ZfKD: angestrebt ist die Verwendung eines einzelnen Erhebungszeitpunkts (z.B. Dezember)

```
_tu = (Patient  
  # to get tum cols  
  .join(Tumor, "oBDS_RKIPatientId", "inner")  
  .filter(f"Verstorben = 'N' and year(cast(DatumVitalStatus as date)) between 2020 and {dy_max}")  
  # apply tum filter  
  .filter(fil_dy)  
  .project("z_kkr_label, month(cast(DatumVitalStatus as date)) as Vitalstatus_MM, oBDS_RKIPatientId")  
  # count pat, not tum  
  .aggregate("z_kkr_label,Vitalstatus_MM, count(distinct oBDS_RKIPatientId) as cnt")  
  .order("z_kkr_label,Vitalstatus_MM")  
  .to_df()  
  .astype({"Vitalstatus_MM": "Int64"}).astype({"Vitalstatus_MM": str})  
)  
_tu.Vitalstatus_MM = _tu.Vitalstatus_MM.str.zfill(2)  
=pls.plot_stackedBars(_tu.rename(columns={"cnt":"pct"}), orientation='v', show_total=True, normalize=False, relative=True, height=1000,  
  renderer="png")  
# todo wo ist NW
```



Numerische Variablen ¹²₃₄


```
df_numerics = (
    Tumor.project("""--sql
        ,z_kkr_label
        ,z_age
        ,Tumordicke
        ,Anzahl_Tage_Diagnose_Tod::int as Anzahl_Tage_Diagnose_Tod
        ,PSA
        ,LK_befallen::int as LK_befallen
        ,LK_untersucht::int as LK_untersucht
        ,RektumAbstandAnokutanlinie::int as RektumAbstandAnokutanlinie
        ,LDH::int as LDH
        """)
    .order("z_kkr_label")
    .to_df()
)
```

Diagnosealter

- berechnet aus **Diagnosejahr - Geburtsjahr**
- negative Werte entstehen aus falscher Datumsreihenfolge von Ereignissen
- die Datumsangaben sind **nicht bereinigt**, um strukturelle Effekte sichtbar zu machen

💡 HH: "Ja, das liegt an dem Geschätzt-Flag in den Datumsangaben. In unseren Daten haben wir noch die alte Ausprägung 'Jahr geschätzt', diese wird dann im ZFKD-Datensatz mit 'Vollständig geschätzt' übersetzt. Theoretisch könnten Sie statt 1900 auch das angegebene Jahr nutzen... Aber diese Schätz-Angabe ist uns auch ein Dorn im Auge. Wir werden es auch noch in unseren Daten bereinigen. Zumeist handelt es sich da bei uns um Dokumentations oder Verständnisfehler."

```
_ = plt.plot_box_large(df_numerics["z_age"].dropna(), height=150, width=2000, summary=False)
_ = plt.plot_boxes_large(df_numerics[["z_kkr_label", "z_age"]].dropna(), height=600, width=2000, )
```




column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew	kurto
z_age	3_241_401.00	-121.00	30.17	59.75	70.17	68.14	79.50	108.50	123.67	15.21	0.22	220_885_151.06	-1.26	5.03


column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew	kurto
01-SH	150_685.00	-65.75	31.83	61.17	72.33	69.85	80.75	106.67	112.50	14.30	0.20	10_526_086.49	-0.89	1.14
02-HH	55_559.00	-67.17	22.50	56.25	68.67	66.15	78.75	103.50	103.50	16.19	0.24	3_675_406.72	-0.76	0.99
03-NI	216_710.00	-90.17	30.25	58.83	68.75	67.03	77.92	105.33	105.33	14.23	0.21	14_526_445.88	-0.88	1.93
04-HB	25_182.00	-85.83	32.08	61.08	71.67	69.36	80.42	107.33	107.33	15.00	0.22	1_746_681.28	-1.23	4.39
05-NW	805_679.00	0.00	30.08	60.33	70.92	69.14	80.50	110.58	123.67	14.83	0.21	55_707_787.00	-0.69	0.81
06-HE	174_565.00	-103.08	27.75	57.42	67.92	65.82	77.25	105.00	123.67	15.61	0.24	11_489_971.53	-1.28	4.99
07-RP	123_111.00	-83.25	29.83	58.97	68.58	66.89	77.92	102.75	123.67	14.60	0.22	8_235_295.90	-0.84	1.78
08-BW	362_189.00	-100.58	28.00	58.62	69.67	67.35	79.58	107.83	123.17	16.66	0.25	24_393_498.26	-1.62	6.72
09-BY	431_813.00	-121.00	28.83	58.33	68.75	66.65	78.00	106.67	123.25	15.83	0.24	28_780_598.59	-1.53	7.16
10-SL	48_061.00	-36.58	32.08	61.00	70.75	69.23	80.33	103.92	103.92	14.43	0.21	3_327_310.08	-0.81	0.94
11-BE	114_910.00	-94.33	24.33	56.92	68.75	65.83	78.67	106.75	123.25	17.67	0.27	7_564_274.42	-1.84	8.91
12-BB	104_299.00	-99.92	28.83	58.33	68.00	66.51	78.00	107.33	108.50	14.98	0.23	6_936_657.61	-1.11	4.69
13-MV	110_032.00	-96.58	33.92	61.25	70.42	68.97	79.50	106.25	123.17	13.72	0.20	7_588_761.64	-0.97	2.75
14-SN	300_228.00	-80.83	37.50	63.25	72.67	70.50	80.42	105.00	122.00	13.57	0.19	21_167_261.67	-1.21	3.72
15-ST	126_193.00	-101.42	34.92	62.00	71.58	69.38	80.08	103.42	123.50	15.86	0.23	8_755_539.57	-2.74	17.81
16-TH	92_185.00	-81.83	37.17	62.75	71.83	70.12	79.83	103.08	120.17	13.15	0.19	6_463_574.42	-1.24	5.24

Anzahl Tage zwischen Diagnose und Tod

- 💡 ZFKD: "es treten Extremwerte auf, weit ausserhalb des Interquartilsabstandes. Grund dafür sind mutmasslich fehlende Datumsangaben, die auf 1900 kodiert werden"
- 💡 ZFKD: "in der KKR Verteilung sind die Extreme in den GTDS Ländern besonders ausgeprägt"

```
_ = plt.plot_box_large(df_numerics["Anzahl_Tage_Diagnose_Tod"].dropna(), height=150, width=2000, use_log=True, summary=False)
_ = plt.plot_boxes_large(df_numerics[["z_kkr_label", "Anzahl_Tage_Diagnose_Tod"]].dropna(), height=400, width=2000, summary=True, use_log=True)
```







column	skew	kurto	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum
Anzahl_Tage_Diagnose_Tod	880_655.00	-27_320.00	-212.00	48.00	238.00	599.84	633.00	1_510.00	81_801.00	1_218.24	2.03			
528_249_239.00	5.34	60.95												
column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew	kurto
01-SH	40_150.00	0.00	0.00	29.00	193.00	336.30	527.00	1_274.00	1_783.00	381.00	1.13	13_502_416.00	1.29	0.96
02-HH	17_931.00	0.00	0.00	34.00	163.00	301.89	456.00	1_089.00	1_784.00	350.89	1.16	5_413_197.00	1.48	1.67
03-NI	62_000.00	0.00	0.00	72.00	238.00	354.04	529.00	1_214.00	1_752.00	352.65	1.00	21_950_735.00	1.28	1.05
04-HB	7_806.00	0.00	0.00	25.00	145.00	287.97	451.00	1_089.00	1_688.00	339.30	1.18	2_247_856.00	1.41	1.37
05-NW	230_941.00	0.00	0.00	28.00	187.00	333.87	523.00	1_265.00	1_847.00	383.06	1.15	77_103_307.00	1.33	1.10
06-HE	52_053.00	0.00	0.00	84.00	287.00	560.95	674.00	1_559.00	20_880.00	905.90	1.61	29_199_049.00	5.12	44.28
07-RP	25_580.00	0.00	0.00	57.00	197.00	309.62	463.00	1_072.00	1_857.00	324.37	1.05	7_920_133.00	1.43	1.68
08-BW	113_669.00	0.00	0.00	55.00	243.00	373.43	577.00	1_360.00	2_043.00	391.38	1.05	42_447_082.00	1.26	1.01
09-BY	123_325.00	0.00	0.00	43.00	281.00	1_030.24	880.00	2_135.00	81_801.00	1_963.93	1.91	127_054_702.00	3.90	41.00
10-SL	2_724.00	0.00	0.00	0.00	0.00	36.19	8.00	20.00	1_309.00	120.67	3.33	98_573.00	5.37	34.83
11-BE	36_804.00	0.00	0.00	24.00	160.00	374.32	496.00	1_204.00	12_262.00	625.57	1.67	13_776_593.00	5.23	47.28
12-BB	35_635.00	0.00	0.00	38.00	222.00	894.02	729.00	1_765.00	18_846.00	1_772.39	1.98	31_858_484.00	3.19	11.46
13-MV	25_806.00	-27_320.00	-212.00	113.00	394.00	1_146.03	1_127.00	2_648.00	16_507.00	1_859.12	1.62	29_574_535.00	2.19	10.59
14-SN	73_771.00	0.00	0.00	137.00	487.00	1_329.08	1_450.00	3_419.00	30_549.00	2_020.37	1.52	98_047_409.00	2.55	8.28
15-ST	19_946.00	0.00	0.00	24.00	158.00	723.30	557.00	1_355.00	14_859.00	1_543.28	2.13	14_426_989.00	3.48	13.45
16-TH	12_514.00	0.00	0.00	84.00	336.00	1_089.03	1_100.00	2_623.00	17_766.00	1_823.47	1.67	13_628_179.00	2.82	9.59

Tumordicke

```
_=pls.plot_box_large(df_numerics["Tumordicke"].dropna(), height=150, width=2000, use_log=False, violin=False)
_=pls.plot_boxes_large(df_numerics[["z_kkr_label", "Tumordicke"]].dropna(), height=400, width=2000, summary=False, use_log=True)
```




column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew	kurto
Tumordicke	26_869.000	0.100	0.100	0.400	0.700	1.732	1.700	3.600	99.000	3.269	1.887	46_537.301	8.608	145.978




PSA

```
_=pls.plot_box_large(df_numerics["PSA"].dropna(), height=150, width=2000, use_log=True, violin=False)
_=pls.plot_boxes_large(df_numerics[["z_kkr_label", "PSA"]].dropna(), height=400, width=2000, summary=False, use_log=True)
```




column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew	kurto
PSA	145_564.000	0.000	0.000	5.720	8.930	94.472	18.900	38.670	89_280.000	728.099	7.707	13_751_674.000	40.436	3_056.587




LK_befallen

```
_=pls.plot_box_large(df_numerics["LK_befallen"].dropna(), height=150, width=2000, use_log=False, violin=False)
_=pls.plot_boxes_large(df_numerics[["z_kkr_label", "LK_befallen"]].dropna(), height=400, width=2000, summary=False, use_log=True)
```




column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew	kurto
LK_befallen	633_804.000	0.000	0.000	0.000	0.000	0.911	0.000	0.000	722.000	3.095	3.397	577_541.000	26.011	4_711.823




LK_untersucht

```
_=pls.plot_box_large(df_numerics["LK_untersucht"].dropna(), height=150, width=2000, use_log=False, violin=False)
_=pls.plot_boxes_large(df_numerics[["z_kkr_label", "LK_untersucht"]].dropna(), height=400, width=2000, summary=False, use_log=True)
```




column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew	kurto
LK_untersucht	761_827.000	0.000	0.000	0.000	5.000	10.543	17.000	42.000	2_319.000	13.518	1.282	8_031_748.000	14.152	1_864.316




RektumAbstandAnokutanlinie

```
_=pls.plot_box_large(df_numerics["RektumAbstandAnokutanlinie"].dropna(), height=150, width=2000, use_log=False, violin=False)
_=pls.plot_boxes_large(df_numerics[["z_kkr_label", "RektumAbstandAnokutanlinie"]].dropna(), height=400, width=2000, summary=False, use_log=True)
```




column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew
RektumAbstandAnokutanlinie	32_714.000	0.000	0.000	5.000	10.000	11.615	14.000	27.000	930.000	18.365	1.581	379_983.000	14.739
kurto	457.717												



LDH

```
_=pls.plot_box_large(df_numerics["LDH"].dropna(), height=150, width=2000, use_log=False, violin=False)
_=pls.plot_boxes_large(df_numerics["z_kkr_label", "LDH"].dropna(), height=400, width=2000, summary=False, use_log=True)
```



column	count	min	lower	q25	median	mean	q75	upper	max	std	cv	sum	skew	kurto
LDH	2_231.000	1.000	83.000	174.000	200.000	219.252	235.000	326.000	3_650.000	141.193	0.644	489_151.000	10.445	190.188

