

Technische Prüfungen in klinischen und epi Daten

Inhalt

- Technische Prüfungen in klinischen und epi Daten
 - Hintergrund
 -  settings
 - Datenstand 
 - klinisch
 - epi
 - Anteil Mehrfach Tumore in epi Daten
 - Plausibilitätsprüfungen
 -  01-SH
 -  02-HH
 -  03-NI
 -  04-HB
 -  05-NW
 -  06-HE
 -  07-RP
 -  08-BW
 -  09-BY
 -  10-SL
 -  11-GKR (ehemals)
 - Qualitätsprüfungen
 -  geschlecht_missing
 -  verstorben_missing
 -  diagnose_missing
 -  diagnose_ausserhalb
 -  inzidenzort_missing
 -  geschlecht_icd_konflikt
 -  datum_missing
 -  datum_fehlerhaft
 - nach hat_todesursache bei Nicht-Verstorbenen
 -  Duplikate
 - Echte Duplikate
 - Duplikatverdacht
 - Verteilung nach Inzidenzort
 - Verteilung nach Diagnosejahr
 - Verteilung nach ICD10
 - Verteilung der Gruppen mit gleichen Merkmalen
 - Beispiel Duplikatverdacht bei epi Daten

Hintergrund

- Ziel der Auswertungen ist es, Qualitätsprüfungen auf **technischer** Ebene darzustellen
- im Abgrenzung zu den **inhaltlichen** Prüfungen des klinischen Datenberichtes sollen hier eher Auffälligkeiten des Verarbeitungsprozesses sichtbar werden, z.B. missings / Konflikte bei zentralen Variablen wie Datumsangaben, Geschlecht etc.
- die Auswertungen sind angelehnt an die bei den epi Daten etablierten *ABC Prüfungen* (siehe [Bericht zur Datenqualität \(epi2023\)](#))
- die Abgrenzung dieses Dokumentes zum DQ Bericht epi ist derzeit nicht zufriedenstellend gelöst und muss zukünftig verbessert werden
- dargestellt sind hier jeweils Auffälligkeiten sowohl in den klinischen als auch in den epi Daten
- weiterhin nehmen wir bei keinem dieser Prüfungen eine Korrektur in den **klinischen Daten** vor

settings

 3.12.8 |  pandas: 2.3.3 |  numpy: 1.26.4 |  duckdb: 1.5.0 | 
pandas-plots: 2.0.7

Datenstand

klinisch

```
database file:      2026-05-12_data_clin.duckdb
data tag:           v2.4
last kkr data import: 2026-04-18
sql table created:  2026-05-12 16:38:32
doi:               10.18444/5.03.01.0005.0021.0003
document created:   2026-05-27 17:15:29
```

epi

```
database file:      2026-05-13_data_epi.duckdb
data tag:           epi2025_1
sql table created:  2026-05-13 09:31:01
doi:               10.18444/5.03.01.0005.0022.0001
document created:   2026-05-27 17:15:29
```

```
aktuellster batch      426
aktuellstes Diagnosejahr  (2024)
```

Anteil Mehrfachtumore in epi Daten

- Metrik: Anteil Tumore mit **A_Mehrfachmeldung** (Werte sind in % angegeben)
- markierte Mehrfachtumore werden vom ZfKD ausgeschlossen
- **!** Daten ab 2020 in den NBL sind aus klin Daten übernommen

💡 ZfKD

für **13-NI**, **14-SN** und **15-ST** ermittelt das ZfKD sichtbar erhöhte Anteile an Mehrfachtumoren für DJ seit Beginn der klin. Registrierung

n = 17_758_787 (100.0%)
 L [DJ 2010–2024]: n = 11_720_684 (66.0%)
 L [nur gültige BL]: n = 11_711_456 (65.9%)

bl	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
x_dy																	
2010	0.10	2.16	0.95	0.03	0.07	0.15	0.11	0.33	0.18	2.78	0.51	0.78	0.73	1.45	0.76	1.20	0.48
2011	0.03	2.22	1.02	0.10	0.09	0.19	0.15	0.41	0.18	2.40	0.63	0.88	1.09	1.46	0.65	1.21	0.50
2012	0.02	1.87	1.04	0.06	0.09	0.13	0.19	0.43	0.17	2.63	0.73	0.86	1.00	1.50	0.69	1.20	0.51
2013	0.01	1.67	1.23	0.11	0.13	0.17	0.25	0.73	0.21	3.19	0.72	0.91	1.02	1.42	0.70	1.37	0.59
2014	0.01	1.28	1.29	0.14	0.18	0.24	0.33	0.86	0.20	5.31	0.76	0.79	0.97	1.45	0.85	1.31	0.66
2015	0.02	1.04	1.41	0.41	0.23	0.10	0.44	0.78	0.17	4.83	0.82	0.75	1.08	1.31	0.88	1.30	0.67
2016	0.24	0.97	1.34	0.38	0.35	0.08	0.67	0.75	0.24	4.80	1.03	0.99	1.06	1.35	1.05	1.23	0.74
2017	0.41	0.90	1.25	0.37	0.64	0.17	0.82	0.76	0.26	4.83	1.73	1.42	1.11	1.52	0.82	1.52	0.88
2018	0.33	0.87	1.37	0.35	0.40	0.20	0.84	0.71	0.26	4.74	1.62	1.48	1.14	1.61	1.09	1.28	0.83
2019	0.41	0.82	1.46	0.29	0.35	0.22	1.03	0.63	0.30	4.78	1.34	1.26	0.97	1.55	0.96	1.17	0.80
2020	0.40	0.93	1.44	0.36	0.92	0.26	0.87	0.66	0.38	4.69	1.12	1.04	1.62	4.19	4.44	1.11	1.24
2021	0.39	0.87	1.38	0.29	0.32	0.20	0.85	0.64	0.29	4.83	1.32	1.09	2.58	6.37	6.84	1.61	1.33
2022	0.39	0.80	1.34	0.36	0.13	0.24	0.76	0.64	0.32	5.15	1.67	1.31	5.23	7.77	9.12	1.49	1.54
2023	0.37	0.79	1.47	0.42	0.13	0.26	0.61	0.57	0.19	4.55	1.75	1.73	7.92	9.02	10.30	1.78	1.76
2024	0.36	0.75	1.95	0.29	0.12	0.19	0.64	0.56	0.16	3.78	1.81	1.62	9.03	5.17	11.46	2.12	1.57

Plausibilitätsprüfungen

Filter

- es ist jeweils nur das aktuellste DJ berücksichtigt (aktuell **epi2025**: 2024, zum Vergleich **epi2024**: 2023)

Die Tabellen sind zur besseren Lesbarkeit nun aufgeteilt nach den Plausibilitätsprüfungen ([Liste als pdf](#), [Details als pdf](#))

- **A**: Fälle ausgeschlossen
- **B**: Fälle markiert
- **C**: Fälle (auto) korrigiert

Spalten

- **cnt_epi2024**: Absolute Fallzahl der checks für das in diesem Datensatz höchste DJ (2023)
- **cnt_now**: Absolute Fallzahl der checks für das im aktuellen Datensatz höchsten DJ (2024)
- **pct_epi2024**: Anteil Fallzahl der checks an allen Fällen für das in diesem Datensatz höchste DJ (2023)
- **pct_now**: Anteil Fallzahl der checks an allen Fällen für das im aktuellen Datensatz höchste DJ (2024)
- (Absolute Fallzahlen = nach Abzug der A-Prüfungen)

Die markierten Fälle können im übermittelten Datensatz geprüft werden, Beispiel:

► click

```
select *
from Tumor4
where IARC like '%A_Mehrfach%'
```

✓ 01-SH

- B_TOD_Ja_Aber_Kein_SJ: 0 -> 4%
- alle Fälle wurden korrigiert laut C_TOD=1_korrigiert_aufgrund_Sterbeangaben

check_label	cnt_epi2024	cnt_now	pct_epi2024	pct_now
A_ICD10_SEX_fehlerhaft[66]	1	nan	0	nan
A_ICD10_keineAuswertung[54]	1	nan	0	nan
A_Mehrfachmeldung[37]	121	132	0	0
I_Fallzahl[48]	34_512	36_307	100	100
check_label	cnt_epi2024	cnt_now	pct_epi2024	pct_now
B_DALT_HISC_ICD10_unplausibel[67]	12	14	0	0
B_DCO_DDIMP_inkonsistent[39]	8	8	0	0
B_DIG_HISC_unplausibel[70]	44	53	0	0
B_DIG_ICDO3_unplausibel[69]	nan	1	nan	0
B_DSICH_HISC_unplausibel[72]	130	102	0	0
B_Entscheidung_Mehrfachtumor_unplaus	4	9	0	0
B_GRAD_HISC_unplausibel[85]	44	45	0	0
B_HISC_ICDO3_unplausibel[55]	222	209	1	1
B_TNMM_GROBST_unplausibel[78]	109	95	0	0
B_TNMT_DIG_unplausibel[20]	12	12	0	0
B_TNMTx_ICD10_unplausibel[76]	10	17	0	0
B_TOD_Ja_Aber_Kein_SJ[12]	nan	1_511	nan	4
I_Fallzahl[48]	34_512	36_307	100	100
check_label	cnt_epi2024	cnt_now	pct_epi2024	pct_now
C_DIG_korrigiert[64]	2	4	0	0
C_HISC_korrigiert[56]	5	7	0	0
C_ICD10DREI_korrigiert[80]	156	192	0	1
C_ICDO3_korrigiert[52]	43	43	0	0
C_LOKS_korrigiert[84]	137	194	0	1
C_SJ>MaxJahr[14]	2_555	nan	7	nan
C_TOD=1_korrigiert_aufgrund_Sterbeangab	nan	1_511	nan	4
I_Fallzahl[48]	34_512	36_307	100	100

✓ 02-HH

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_Mehrfachmeldung[37]	176	136	1	1
A_SEX_fehlerhaft[1]	1	4	0	0
I_Fallzahl[48]	18_011	17_987	100	100
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	6	9	0	0
B_DCO_DDIMP_inkonsistent[39]	33	25	0	0
B_DIG_HISC_unplausibel[70]	197	169	1	1
B_DSICH_HISC_unplausibel[72]	243	250	1	1
B_Entscheidung_Mehrfachtumor_unplaus	nan	4	nan	0
B_GRAD_HISC_unplausibel[85]	19	20	0	0
B_HISC_ICDO3_unplausibel[55]	318	269	2	1
I_Fallzahl[48]	18_011	17_987	100	100
check_label				
C_DJ_korrigiert_aufgrund_DSICH[43]	81	76	0	0
C_HISC_korrigiert[56]	6	16	0	0
C_ICD10DREI_korrigiert[80]	58	57	0	0
C_ICDO3_korrigiert[52]	2	3	0	0
C_LOKS_korrigiert[84]	216	237	1	1
I_Fallzahl[48]	18_011	17_987	100	100

03-NI

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_ICD10_keineAuswertung[54]	147	151	0	0
A_Mehrfachmeldung[37]	1_256	1_882	1	2
A_Zeitangaben_fehlerhaft[58]	2	nan	0	nan
I_Fallzahl[48]	86_331	87_692	100	100
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	35	56	0	0
B_DCO_DDIMP_inkonsistent[39]	101	109	0	0
B_DIG_HISC_unplausibel[70]	420	401	0	0
B_DSICH_HISC_unplausibel[72]	697	671	1	1
B_Entscheidung_Mehrfachtumor_unplaus	1	1	0	0
B_GRAD_HISC_unplausibel[85]	125	143	0	0
B_HISC_ICDO3_unplausibel[55]	1_175	1_172	1	1
B_PatAngaben_inkonsistent[60]	2	11	0	0
B_TNMM_GROBST_unplausibel[78]	2	6	0	0
B_TNMT_DIG_unplausibel[20]	nan	6	nan	0
B_TNMx_ICD10_unplausibel[76]	199	nan	0	nan
B_TOD_Ja_Aber_Kein_SJ[12]	6	38	0	0
I_Fallzahl[48]	86_331	87_692	100	100
check_label				
C_DIG_korrigiert[64]	nan	10	nan	0
C_DJ_korrigiert_aufgrund_DSICH[43]	7	nan	0	nan
C_HISC_korrigiert[56]	558	300	1	0
C_ICD10DREI_korrigiert[80]	1_235	1_974	1	2
C_LOKS_korrigiert[84]	516	417	1	0
C_Sj>MaxJahr[14]	6_518	8_165	8	9
C_TNMx_korrigiert[44]	166	129	0	0
C_TOD=1_korrigiert_aufgrund_Sterbeang:	5	38	0	0
I_Fallzahl[48]	86_331	87_692	100	100

04-HB

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_ICD10_keineAuswertung[54]	4	5	0	0
A_Mehrfachmeldung[37]	25	14	0	0
A_SEX_fehlerhaft[1]	2	nan	0	nan
I_Fallzahl[48]	5_068	4_687	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	6	6	0	0
B_DCO_DDIMP_inkonsistent[39]	4	2	0	0
B_DiG_HISC_unplausibel[70]	34	85	1	2
B_DSICH_HISC_unplausibel[72]	48	32	1	1
B_Entscheidung_Mehrfachtumor_unplaus	1	1	0	0
B_GRAD_HISC_unplausibel[85]	12	8	0	0
B_HISC_ICDO3_unplausibel[55]	85	114	2	2
B_TNMT_DiG_unplausibel[20]	5	3	0	0
B_TNMx_ICD10_unplausibel[76]	nan	5	nan	0
I_Fallzahl[48]	5_068	4_687	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
C_DiG_korrigiert[64]	nan	1	nan	0
C_HISC_korrigiert[56]	3	9	0	0
C_ICD10DREI_korrigiert[80]	16	13	0	0
C_ICDO3_korrigiert[52]	4	nan	0	nan
C_LOKS_korrigiert[84]	81	69	2	1
I_Fallzahl[48]	5_068	4_687	100	100

⚠ 05-NW

- unverändert hohe werte bei A_EKRRN_GKZ_unplausibel

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_EKRRN_GKZ_unplausibel[83]	21_338	24_338	11	11
A_ICD10_keineAuswertung[54]	748	754	0	0
A_Mehrfachmeldung[37]	255	279	0	0
I_Fallzahl[48]	202_655	215_180	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	99	90	0	0
B_DALT_unplausibel[77]	nan	1	nan	0
B_DCO_DDIMP_inkonsistent[39]	38	30	0	0
B_DiG_HISC_unplausibel[70]	2_026	2_198	1	1
B_DSICH_HISC_unplausibel[72]	1_565	1_697	1	1
B_Entscheidung_Mehrfachtumor_unplaus	16	13	0	0
B_GRAD_HISC_unplausibel[85]	121	96	0	0
B_HISC_ICDO3_unplausibel[55]	2_767	3_074	1	1
B_PatAngaben_inkonsistent[80]	1	nan	0	nan
B_TNMx_ICD10_unplausibel[76]	84	198	0	0
I_Fallzahl[48]	202_655	215_180	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
C_HISC_korrigiert[56]	527	554	0	0
C_ICD10DREI_korrigiert[80]	636	540	0	0
C_ICDO3_korrigiert[52]	130	257	0	0
C_LOKS_korrigiert[84]	117	224	0	0
C_SJ>MaxJahr[14]	15_419	14_954	8	7
C_TNMx_korrigiert[44]	1	nan	0	nan
I_Fallzahl[48]	202_655	215_180	100	100

✅ 06-HE

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_ICD10_keineAuswertung[54]	1	1	0	0
A_Mehrfachmeldung[37]	114	82	0	0
A_SEX_fehlerhaft[1]	nan	4	nan	0
I_Fallzahl[48]	44_073	42_721	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	30	34	0	0
B_DALT_unplausibel[77]	1	nan	0	nan
B_DCO_DDIMP_inkonsistent[39]	55	34	0	0
B_DIG_HISC_unplausibel[70]	285	260	1	1
B_DIG_ICDO3_unplausibel[69]	nan	1	nan	0
B_DSICH_HISC_unplausibel[72]	560	563	1	1
B_Entscheidung_Mehrfachtumor_unplaus	6	10	0	0
B_GRAD_HISC_unplausibel[85]	47	35	0	0
B_HISC_ICDO3_unplausibel[55]	709	677	2	2
B_PatAngaben_inkonsistent[60]	14	222	0	1
B_TNMM_GROBST_unplausibel[78]	42	9	0	0
B_TNMT_DIG_unplausibel[20]	26	38	0	0
B_TNMx_ICD10_unplausibel[76]	4	10	0	0
B_TOD_Ja_Aber_Kein_SJ[12]	1	2	0	0
I_Fallzahl[48]	44_073	42_721	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
C_DIG_korrigiert[64]	1	1	0	0
C_HISC_korrigiert[56]	43	29	0	0
C_ICD10DREI_korrigiert[80]	203	143	0	0
C_ICDO3_korrigiert[52]	43	39	0	0
C_LOKS_korrigiert[84]	178	139	0	0
C_SJs>MaxJahr[14]	3_710	2_622	8	6
I_Fallzahl[48]	44_073	42_721	100	100

✓ 07-RP

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_Mehrfachmeldung[37]	184	232	1	1
I_Fallzahl[48]	30_000	31_878	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	12	18	0	0
B_DCO_DDIMP_inkonsistent[39]	24	6	0	0
B_DIG_HISC_unplausibel[70]	240	181	1	1
B_DIG_ICDO3_unplausibel[69]	nan	1	nan	0
B_DSICH_HISC_unplausibel[72]	563	593	2	2
B_Entscheidung_Mehrfachtumor_unplaus	11	7	0	0
B_GRAD_HISC_unplausibel[85]	9	10	0	0
B_HISC_ICDO3_unplausibel[55]	545	495	2	2
B_TNMx_ICD10_unplausibel[76]	24	23	0	0
I_Fallzahl[48]	30_000	31_878	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
C_HISC_korrigiert[56]	284	246	1	1
C_ICD10DREI_korrigiert[80]	202	206	1	1
C_ICDO3_korrigiert[52]	16	24	0	0
C_LOKS_korrigiert[84]	777	772	3	2
C_SJs>MaxJahr[14]	2_047	2_421	7	8
C_TNMx_korrigiert[44]	nan	3	nan	0
I_Fallzahl[48]	30_000	31_878	100	100

✓ 08-BW

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_ICD10_keineAuswertung[54]	427	349	1	0
A_Mehrfachmeldung[37]	444	486	1	1
A_SEX_fehlerhaft[1]	6	10	0	0
A_Zeitangaben_fehlerhaft[58]	9	13	0	0
I_Fallzahl[48]	81_320	82_957	100	100
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	56	65	0	0
B_DCO_DDIMP_inkonsistent[39]	16	30	0	0
B_DIG_HISC_unplausibel[70]	1_024	1_149	1	1
B_DSICH_HISC_unplausibel[72]	515	502	1	1
B_Entscheidung_Mehrfachtumor_unplaus	22	31	0	0
B_GRAD_HISC_unplausibel[85]	89	98	0	0
B_HISC_ICDO3_unplausibel[55]	1_745	1_938	2	2
B_PatAngaben_inkonsistent[60]	2	1	0	0
B_TNMT_DIG_unplausibel[20]	139	140	0	0
B_TNMx_ICD10_unplausibel[76]	24	12	0	0
I_Fallzahl[48]	81_320	82_957	100	100
check_label				
C_DIG_korrigiert[64]	2	nan	0	nan
C_DJ_korrigiert_aufgrund_DSICH[43]	6	1	0	0
C_HISC_korrigiert[56]	133	153	0	0
C_ICD10DREI_korrigiert[80]	471	684	1	1
C_ICDO3_korrigiert[52]	27	63	0	0
C_LOKS_korrigiert[84]	515	539	1	1
C_SJ>MaxJahr[14]	1_018	2_785	1	3
I_Fallzahl[48]	81_320	82_957	100	100

✓ 09-BY

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_ICD10_keineAuswertung[54]	232	188	0	0
A_Mehrfachmeldung[37]	86	140	0	0
A_SEX_fehlerhaft[1]	7	1	0	0
I_Fallzahl[48]	84_717	86_674	100	100
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	42	51	0	0
B_DCO_DDIMP_inkonsistent[39]	16	54	0	0
B_DIG_HISC_unplausibel[70]	271	307	0	0
B_DSICH_HISC_unplausibel[72]	476	666	1	1
B_Entscheidung_Mehrfachtumor_unplaus	2	5	0	0
B_GRAD_HISC_unplausibel[85]	81	83	0	0
B_HISC_ICDO3_unplausibel[55]	729	836	1	1
B_TNMM_GROBST_unplausibel[78]	43	19	0	0
B_TNMT_DIG_unplausibel[20]	7	8	0	0
B_TNMx_ICD10_unplausibel[76]	19	4	0	0
I_Fallzahl[48]	84_717	86_674	100	100
check_label				
C_HISC_korrigiert[56]	59	69	0	0
C_ICD10DREI_korrigiert[80]	229	225	0	0
C_ICDO3_korrigiert[52]	55	60	0	0
C_LOKS_korrigiert[84]	3_535	1_324	4	2
C_SJ>MaxJahr[14]	3_707	4_051	4	5
I_Fallzahl[48]	84_717	86_674	100	100

✓ 10-SL

- A_Mehrfachmeldung leicht erhöht mit ~4%

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_ICD10_SEX_fehlerhaft[66]	1	1	0	0
A_ICD10_keineAuswertung[54]	18	13	0	0
A_Mehrfachmeldung[37]	239	510	2	4
I_Fallzahl[48]	11_076	12_247	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	9	4	0	0
B_DCO_DDIMP_inkonsistent[39]	16	14	0	0
B_DIG_HISC_unplausibel[70]	50	41	0	0
B_DSICH_HISC_unplausibel[72]	136	174	1	1
B_Entscheidung_Mehrfachtumor_unplaus	3	3	0	0
B_GRAD_HISC_unplausibel[85]	14	16	0	0
B_HISC_ICDO3_unplausibel[55]	175	148	2	1
B_PatAngaben_inkonsistent[60]	nan	2	nan	0
B_TNMT_DIG_unplausibel[20]	9	10	0	0
B_TNMx_ICD10_unplausibel[76]	15	13	0	0
I_Fallzahl[48]	11_076	12_247	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
C_DIG_korrigiert[64]	27	21	0	0
C_DJ_korrigiert_aufgrund_DSICH[43]	3	6	0	0
C_HISC_korrigiert[56]	49	46	0	0
C_ICD10DREI_korrigiert[80]	110	118	1	1
C_ICDO3_korrigiert[52]	4	12	0	0
C_LOKS_korrigiert[84]	26	53	0	0
C_SJ>MaxJahr[14]	71	69	1	1
I_Fallzahl[48]	11_076	12_247	100	100

✓ 11-GKR (ehemals)

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
A_Datuemer>MaxJahr[59]	nan	1	nan	0
A_EKRRNR_GKZ_unplausibel[83]	98	87	0	0
A_ICD10_SEX_fehlerhaft[66]	5	3	0	0
A_ICD10_keineAuswertung[54]	2_876	2_180	2	1
A_Mehrfachmeldung[37]	12_272	8_712	8	6
A_SEX_fehlerhaft[1]	24	18	0	0
A_Zeitangaben_fehlerhaft[58]	5	2	0	0
I_Fallzahl[48]	155_450	146_457	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
B_DALT_HISC_ICD10_unplausibel[67]	60	48	0	0
B_DALT_unplausibel[77]	9	10	0	0
B_DCO_DDIMP_inkonsistent[39]	19	11	0	0
B_DIG_HISC_unplausibel[70]	1_119	1_249	1	1
B_DIG_ICDO3_unplausibel[69]	1	2	0	0
B_DSICH_HISC_unplausibel[72]	2_189	2_714	1	2
B_Entscheidung_Mehrfachtumor_unplaus	27	30	0	0
B_GRAD_HISC_unplausibel[85]	160	187	0	0
B_HISC_ICDO3_unplausibel[55]	3_059	3_221	2	2
B_PatAngaben_inkonsistent[60]	49	29	0	0
B_TNMT_DIG_unplausibel[20]	330	313	0	0
B_TNMx_ICD10_unplausibel[76]	391	439	0	0
B_TOD_Ja_Aber_Kein_SJ[12]	23	3	0	0
I_Fallzahl[48]	155_450	146_457	100	100

	cnt_epi2024	cnt_now	pct_epi2024	pct_now
check_label				
C_DIG_korrigiert[64]	107	99	0	0
C_DJ_korrigiert_aufgrund_DSICH[43]	93	426	0	0
C_HISC_korrigiert[56]	235	284	0	0
C_ICD10DREI_korrigiert[80]	906	1_057	1	1
C_LOKS_korrigiert[84]	850	833	1	1
C_SJ>MaxJahr[14]	8_636	10_210	6	7
C_TNMx_korrigiert[44]	nan	2	nan	0
C_TOD=1_korrigiert_aufgrund_Sterbeang:	23	3	0	0
I_Fallzahl[48]	155_450	146_457	100	100

Qualitätsprüfungen

- kein Filter, die Prüfungen wirken auf den gesamten Datenbestand
- zur Darstellung wird eine heatmap verwendet, dem maximalen Wert je Prüfung wird die kräftigste Farbe zugewiesen. Aus diesem relativ gesetzten Farbton ist nicht ableitbar, wie schwerwiegend die Fallzahl ist
- bei **epi** Daten
 - für die NBL wird nur **11-GKR_alt** ausgegeben, also der archivierte GKR Bestand vor DJ2020
 - Daten > 2020 werden aus den klinischen Daten generiert
 - Treffer für NBL > 2020 sind also **nicht** enthalten

⚠ geschlecht_missing

- Variable **Geschlecht** / **SEX** missing

  klin

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_missing		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

  epi

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
geschlecht_missing		0	53	0	16	0	1_523	0	618	87	0	25	2_322

✅ verstorben_missing

- Variable **Verstorben** / **TOD** missing

Die Variable **TOD** wird in den epi Daten imputiert, kann also dort auch nicht fehlen

  klin

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
verstorben_missing		0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

  epi

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
verstorben_missing		0	0	0	0	0	0	0	0	0	0	0	0

⚠ diagnose_missing

- Diagnosecode leer (entweder `null` oder `' '`)

  klin

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
diagnose_missing		0	0	0	0	0	0	0	0	0	0	0	0	482	0	0	0	482

  epi

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
diagnose_missing		4	0	2_065	296	13_760	23	9	5_154	3_339	210	226	25_086

⚠ diagnose_ausserhalb

- Diagnosecode ist **nicht leer**, aber ausserhalb des ZfKD Diagnosebandes

⚠ epi: In den ABC Prüfungen der epi Daten wird getestet, ob ein Diagnosecode leer ist oder ausserhalb des "Diagnosebandes" des ZfKD (konkret: `A_ICD10_keineAuswertung[54]`). Der Test ist auch im Datenbericht der epi Daten sichtbar, dort wird allerdings nur das letzte DJ herangezogen, um auf die aktuelle Entwicklung zu fokussieren.

  klin

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
diagnose_ausserhalb		0	0	0	0	1_868	1	0	52	6	0	8	8	11	4	4	0	1_962

  epi

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
diagnose_ausserhalb		4	0	2_065	296	13_760	23	9	5_154	3_339	210	226	25_086

⚠ inzidenzort_missing

- Variable `Inzidenzort` fehlt, oder ist unbrauchbar kodiert (00000, 99999, oder Länge != 5)

epi: die Variable GKZlk wird nachbearbeitet im workflow und weist daher keine missings auf

  klin

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
inzidenzort_missing		0	0	0	0	0	0	0	0	3	0	0	0	188	0	0	0	191

  epi

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
inzidenzort_missing		0	0	0	0	0	0	0	0	0	0	0	0

✓ geschlecht_icd_konflikt

- Widerspruch zwischen Geschlecht und Diagnose, eines der Kombinationen:
 - männlich und ['C51', 'C52', 'C53', 'C54', 'C55', 'C56', 'C57', 'C58']
 - weiblich und ['C60', 'C61', 'C62', 'C63']

  klin

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
geschlecht_icd_konflikt		2	0	2	0	17	4	4	6	11	2	0	2	0	0	2	1	53

  epi

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
geschlecht_icd_konflikt		2	1	0	0	0	0	0	0	1	4	0	8

⚠ datum_missing

- Diagnosedatum oder Geburtsdatum ist leer (bzw. als Jahr 1900 kodiert)
- nicht gesetzte Angaben zum Vitalstatus sind ignoriert

⚠ hier sind auch regulär übermittelte Fälle mit vollständig (V) geschätztem Datum enthalten

  klin

	lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_missing		45	58	226	10	697	283	35	1_472	1_438	13	831	237	71	220	850	121	6_607

  epi

lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
datum_missing	71	313	67	7	586	230	52	0	14	2_120	1_620	5_080

✓ datum_fehlerhaft

- Diagnose vor Geburt
- beide nicht missing

  klin

lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
datum_fehlerhaft	0	0	0	0	0	0	0	0	0	1	0	0	1	0	0	0	2

  epi

lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
datum_fehlerhaft	0	0	0	0	0	0	0	0	0	2	0	2

nach hat_todesursache bei Nicht-Verstorbenen

- gezählt werden **Personen**
- Filter: **Verstorben = N**

lkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH
cnt_tu	1	0	0	0	0	0	0	0	2	15	1	3	478	0	0	2

⚠ Duplikate

- Echte Duplikate stellen Fälle **mit gleicher Id und gleichem hash-wert** dar
- Duplikat-Verdacht: Duplikate **mit gleicher Id, aber ohne inhaltliche Gleichheit** sind häufiger, stellen aber lediglich eine Folge der Id Vergabe im GTDS Verbund dar. Da in der Verarbeitung eine zufällige **uuid** vergeben wird entstehen hier auch keine Kollisionen

Echte Duplikate

- analysiert werden Tumorfälle auf Basis gleicher **Tumor_ID** (original gelieferte Id)
- ebenfalls herangezogen wird ein  hash-wert über eine Auswahl von Spalten
- haben Tumorfälle den gleichen hash-wert, kann eine inhaltliche Gleichheit **angenommen** werden
- **Ergebnis**
 - ~1000 Paare mit echten Duplikaten sind in den Daten, alle aus **09-BY**.

- keine der Paare sind innerhalb einer Lieferdatei, also keine Gefahr für die Verarbeitung
- im Beispiel sind zwei Tumore mit gleicher originalen ID und gleichem hash-wert, aber verschiedenen Dateien
- in allen Duplikaten werden technische ID neu vergeben, es kommt also nicht zu Kollisionen

Tests:

Für den hash-wert sind folgende Spalten herangezogen:

```
z_icd10,
Morphologie_Code,
Topographie_Code,
Geburtsdatum,
Diagnosedatum,
z_sex,
Verstorben,
Inzidenzort,
Seitenlokalisation,
Grading,
Diagnosesicherung,
T_p,
N_p,
M_p
```

Echte Duplikate (gleiche Tumor_ID UND gleicher Inhalt/hash):

kk	same_kkr	same_file	cnt_cases	max_cases_in_dupl	example_Tumor_ID		
0	9	True	False	4	2	0C38B26E95677F0A15C56E8F238CFBFC4D94EB76_1	
z_tum_id			Tumor_ID	z_kkr	FileName	sha_256	
0	b883af94-dabe-4e80-8779-3eb69131f61e		0C38B26E95677F0A15C56E8F238CFBFC4D94EB76_1	9	.\09\zfd2024_00006_mod.xml	5e5066d1aa878705ccd1e9f85db4bb57f9fc358a9ead23...	
1	2854174d-50e8-4a45-a3d6-21abc5f8e4bd		0C38B26E95677F0A15C56E8F238CFBFC4D94EB76_1	9	.\09\zfd2022_00005_mod.xml	5e5066d1aa878705ccd1e9f85db4bb57f9fc358a9ead23...	

Duplikatverdacht

- die originale **Tumor_ID** wird hier ignoriert
- es wird für alle Tumorfälle geprüft, ob es Fälle mit gleicher Kombination verschiedener Merkmale gibt
- Verdachtsfälle mit gleicher Kombination aus verschiedenen Registern und Patienten sind möglich
- die Übereinstimmungswahrscheinlichkeit steigt deutlich, wenn mehr Merkmale leer sind

  klin

kk	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-BE	12-BB	13-MV	14-SN	15-ST	16-TH	Total
duplikat_verdacht	86	750	558	46	1_506	304	297	979	1_233	52	2_916	144	323	461	456	59	10_170


 epi

	kkr	01-SH	02-HH	03-NI	04-HB	05-NW	06-HE	07-RP	08-BW	09-BY	10-SL	11-GKR_alt	Total
duplikat_verdacht		1_121	4_511	13_177	359	21_337	2_229	3_782	2_502	3_680	855	15_964	69_517


Verteilung nach Inzidenzort

 klin

TOP 20 [cnt] by [label], n=10_170


 epi


TOP 20 [cnt] by [label], n=69_517




Verteilung nach Diagnosejahr

 klin

TOP 20 [cnt] by [DJ], n=10_170

  epi


TOP 20 [cnt] by [DJ], n=69_517



Verteilung nach ICD10


  klin

TOP 10 [cnt] by [z_icd10_3d], n=10_170



  epi

TOP 10 [cnt] by [z_icd10_3d], n=69_517



Verteilung der Gruppen mit gleichen Merkmalen

- "Gruppe" = >1 Verdachtsfälle mit gleichen Merkmalen
- verwendete Metriken (jeweils aufgetragen: `is_equal` = "alle Fälle in der Gruppe haben den gleichen Wert")

es gibt wenige Gruppen, in denen die Duplikate aus verschiedenen kkr stammen
in den meisten Gruppen stammen die Duplikate nicht von einem einzelnen Patienten

  klin

10_170 Fälle verteilen sich auf 4_909 Gruppen mit max 14 Fällen in einer Gruppe

Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: REGISTER
{True: 4853, False: 56}

Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: PATIENTID
{False: 4445, True: 464}

  epi

69_517 Fälle verteilen sich auf 34_202 Gruppen mit max 31 Fällen in einer Gruppe

Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: REGISTER
{True: 23536, False: 10666}

Anzahl Gruppen, in denen alle Fälle das gleiche Merkmal aufweisen: PATIENTID
{False: 32773, True: 1429}

Beispiel Duplikatverdacht bei epi Daten

	hash2	z_pat_id	z_tum_id	EKRNR	z_kkr	SEX	z_sex	GDIMP	Geburtsdatum	DDIMP	...	ICDTAUFL	Version	IARC	z_hash	is_deleted	hash2_1	hash2_1_1	cnt	same_kkr	same_pat
0	100004984288446378	050002247804	050003110628	05	5	1	M	1949-02-15	1949-02-15	2016-08-15	...	None	None	A_EKRNR_GKZ_unplausibel	100004984288446378	1	100004984288446378	100004984288446378	2	False	False
1	100004984288446378	030000598933	030000586467	03	3	1	M	1949-02-15	1949-02-15	2016-08-15	...	None	None	None	100004984288446378	0	100004984288446378	100004984288446378	2	False	False
2	10000785445950780423	070000344804	070000405638	07	7	1	M	1931-10-15	1931-10-15	2002-08-15	...	None	None	None	10000785445950780423	0	10000785445950780423	10000785445950780423	2	True	False
3	10000785445950780423	070000465359	070000547784	07	7	1	M	1931-10-15	1931-10-15	2002-08-15	...	None	None	None	10000785445950780423	0	10000785445950780423	10000785445950780423	2	True	False
4	10002116280644873648	050001407845	050003180853	05	5	1	M	1956-05-15	1956-05-15	2025-01-15	...	None	None	A_Datuemer>MaxJahr	10002116280644873648	1	10002116280644873648	10002116280644873648	2	True	False
5	10002116280644873648	050002168483	050003021819	05	5	1	M	1956-05-15	1956-05-15	2025-01-15	...	None	None	A_Datuemer>MaxJahr	10002116280644873648	1	10002116280644873648	10002116280644873648	2	True	False
6	10003289828525467968	110002813844	110003360358	11	11	1	M	2003-12-15	2003-12-15	2024-06-15	...	None	None	B_HISC_ICDO3_unplausibel	10003289828525467968	0	10003289828525467968	10003289828525467968	2	True	False
7	10003289828525467968	110002089390	110002555442	11	11	1	M	2003-12-15	2003-12-15	2024-06-15	...	None	None	B_HISC_ICDO3_unplausibel C_ICD10DREI_korr...	10003289828525467968	0	10003289828525467968	10003289828525467968	2	True	False
8	10003316723887599862	109000319381	100000317439	10	10	1	M	1929-06-15	1929-06-15	1985-06-15	...	9	9	None	10003316723887599862	0	10003316723887599862	10003316723887599862	2	True	False
9	10003316723887599862	109000319257	100000317295	10	10	1	M	1929-06-15	1929-06-15	1985-06-15	...	9	9	None	10003316723887599862	0	10003316723887599862	10003316723887599862	2	True	False

10 rows x 20 columns